

Sadraque Silva Viana

Construção de uma Interface Cérebro-Máquina Baseada em Sinais P300

Belo Horizonte

Novembro de 2014

Sadraque Silva Viana

Construção de uma Interface Cérebro-Máquina Baseada em Sinais P300

Monografia submetida à banca examinadora designada pelo Colegiado Didático do Curso de Graduação em Engenharia de Controle e Automação da Universidade Federal de Minas Gerais, como parte dos requisitos para aprovação na disciplina Projeto Final de Curso.

Universidade Federal de Minas Gerais

Escola de Engenharia

Curso de Graduação em Engenharia de Controle e Automação

Orientador: Dr. Danilo Barbosa Melges, DEE/UFMG

Supervisor: Dr. Alessandro Beda, DELT/UFMG

Belo Horizonte

Novembro de 2014

Sadraque Silva Viana

Construção de uma Interface Cérebro-Máquina Baseada em Sinais P300/ Sadraque Silva Viana. – Belo Horizonte, Novembro de 2014-

71 p. : il. (algumas coloridas) ; 30 cm.

Orientador: Dr. Danilo Barbosa Melges, DEE/UFMG

Monografia de Projeto Final de Curso – Universidade Federal de Minas Gerais
Escola de Engenharia

Curso de Graduação em Engenharia de Controle e Automação, Novembro de 2014.

1. P300. 2. Interface cérebro-máquina. I. Universidade Federal de Minas Gerais. II. Escola de Engenharia. III. Curso de Graduação em Engenharia de Controle e Automação. IV. Construção de uma Interface Cérebro-Máquina Baseada em Sinais P300.

Sadraque Silva Viana

Construção de uma Interface Cérebro-Máquina Baseada em Sinais P300

Monografia submetida à banca examinadora designada pelo Colegiado Didático do Curso de Graduação em Engenharia de Controle e Automação da Universidade Federal de Minas Gerais, como parte dos requisitos para aprovação na disciplina Projeto Final de Curso.

Trabalho aprovado. Belo Horizonte, 27 de novembro de 2014:

Dr. Danilo Barbosa Melges,
DEE/UFMG
Orientador

Dr. Alessandro Beda, DELT/UFMG
Supervisor

Dr. Cristiano Leite de Castro,
DEE/UFMG
Terceiro Membro da Banca

Belo Horizonte

Novembro de 2014

*A meu pai,
o "engenheiro" que me "projetou".*

Agradecimentos

À causa primeira, princípio básico ou impulso criador. Uns chamam Deus, outros acaso, alguns eu nem sei pronunciar. Pela oportunidade de existir, de expandir minha ontologia, de aprender e de contribuir.

A quem eu fui, por me possibilitar ser quem agora eu sou.

À minha família, pelo apoio durante os finais de semana ausentes e pelas noites que passei sem dormir. Talvez agora entendam o motivo. Pela valentia que demonstraram em minha criação.

Ao Danilo, pela enorme demonstração de amizade. A sua influência é fortemente responsável pela visão que construí da vida.

Ao Thiago, pelo apoio em horas difíceis. Sua generosidade me inspira, meu amigo.

Ao David, por me ensinar o valor do esforço, mesmo que eu ainda esteja aprendendo. O seu gosto pelo estudo inspirou fortemente minha rota universitária, e certamente inspira minha vida.

Ao meu orientador Danilo Melges, por resgatar o meu gosto pela pesquisa. Pelo exemplo de que sim, é possível fazer diferente.

Ao pessoal do NEPEB, pela hospitalidade com que me acolheram e por empreenderem uma tarefa tão difícil quanto é a Engenharia Biomédica.

A todos os seres que fizeram, fazem ou ainda farão parte da minha vida. No meu melhor modelo, apesar de todos os nossos problemas, somos exploradores aspirando ao sublime, capazes do inimaginável. "Dada a vastidão do espaço e a imensidão do tempo, é uma alegria ser capaz de compartilhar um planeta e uma época com vocês!"

Obrigado.

“They will gaze up and strain to find the blue dot in their skies. They will love it no less for its obscurity and fragility. They will marvel at how vulnerable the repository of all our potential once was, how perilous our infancy, how humble our beginnings, how many rivers we had to cross before we found our way. (Carl Sagan, Pale Blue Dot, 193)

Resumo

Interfaces cérebro-máquina (ICM) são dispositivos que permitem que pessoas controlem equipamentos e comuniquem-se com o ambiente externo através de sua atividade cerebral. Sua importância surge do fato de que tais dispositivos apresentam-se como solução para aumentar a autonomia e melhorar a qualidade de vida de pessoas que sofrem com doenças neurodegenerativas, tais como a esclerose lateral amiotrófica.

Muitas ICM são baseadas no sinal P300, um potencial relacionado a evento que apresenta um pico proeminente com latência de aproximadamente 300 ms após a ocorrência de um estímulo. A medição do P300 é realizada por meio de eletroencefalografia (EEG) e sua eliciação ocorre quando símbolos de interesse e infrequentes são apresentados de forma intercalada com símbolos rotineiros, de maneira aleatória. O grande desafio na construção de ICM baseadas no P300 é a detecção deste potencial, já que a razão sinal-ruído apresentada por ele é muito baixa, sendo mascarado pela atividade de fundo (EEG espontâneo).

Esta monografia de Projeto Final de Curso propõe desenvolver uma ICM baseada em sinais P300. Para tanto, são investigadas diversas técnicas de processamento de sinais, buscando-se desenvolver um algoritmo que consiga realizar a detecção eficiente do potencial. O seguinte conjunto de técnicas foi selecionado visando-se obter o melhor desempenho da ICM: i) filtragem passa-faixas entre 0,1 e 60Hz; ii) re-referenciamento das derivações de EEG através de *Common Average Referencing* (CAR); iii) cálculo da média coerente das épocas dos sinais; iv) seleção de características através de modelos de regressão logística e *least angle regression* (LARS); v) uso de *support vector regression* (SVR) para detecção dos sinais de EEG que contém o P300.

A ICM desenvolvida com melhor desempenho apresentou taxa de acertos média de 96% e taxa de transferência de informação média de 4,8 *bits/min*. Estes valores são comparáveis com os resultados mais recentes divulgados na literatura e são promissores para a aplicação da ICM por pessoas que sofram com doenças neurodegenerativas.

Palavras-chaves: interface cérebro-máquina, P300, processamento de sinais biomédicos.

Abstract

Brain-computer interfaces (BCI) are devices that enable people to control equipment and communicate with the external environment by means of brain activity. These devices have been considered important tools for increasing autonomy and enhancing the life quality of people with neurodegenerative disabilities, such as amyotrophic lateral sclerosis.

Many BCI are based on the P300 signal, an event related potential that presents a prominent positive peak at about 300 ms post-stimulus. The P300 is commonly measured by means of electroencephalography (EEG) and its elicitation occurs when infrequent symbols of interest are presented alternating with frequent meaningless ones, in a randomized way. The biggest challenge of P300-based BCI is the detection of this potential, since it presents low signal-to-noise ratio, being masked by background activity (spontaneous EEG).

This Final Course Project proposes the development of a P300-based BCI. For this purpose, many signal processing techniques are thus investigated, in order to develop an algorithm that can efficiently detect P300. The following set of techniques was chosen to obtain the best performance of the BCI: i) bandpass filtering between 0.1 and 60 Hz; ii) re-referencing of EEG electrodes by means of Common Average Referencing (CAR); iii) coherent average calculation of EEG epochs; iv) feature selection using logistic regression models and least angle regression (LARS); v) use of support vector regression (SVR) to detect EEG signals that contain P300.

The BCI that presented the best performance achieved a mean accuracy of 96% and mean information transfer rate of 4.8 *bits/min*. These values are comparable to those recently published in the literature and are encouraging with regards to the use of the BCI by people with neurodegenerative disabilities.

Key-words: Brain-computer interface, P300, biomedical signal processing.

Lista de ilustrações

Figura 2.1 –Bandas do EEG	6
Figura 2.2 –Sistema Internacional 10-20 para posicionamento de eletrodos do EEG.	7
Figura 2.3 –Forma de onda típica de PRE.	9
Figura 2.4 –Modelo do PRE.	11
Figura 2.5 –Exemplo do sinal P300.	13
Figura 3.1 –Estrutura geral de uma BCI.	16
Figura 3.2 –Exemplo de soletrador P300.	24
Figura 4.1 –Localização das derivações utilizadas.	27
Figura 4.2 –Ilustração das características baseadas em parâmetros P300.	31
Figura 4.3 –Esquema do LARS.	34
Figura 4.4 –Esquema do classificador SVM.	35
Figura 4.5 –Esquema de regressão baseada em SVR.	38
Figura 4.6 –Diagrama do processamento dos sinais.	40
Figura 5.1 –Sinais <i>target</i> e <i>non-target</i> do primeiro grupo.	43
Figura 5.2 –Sinais <i>target</i> e <i>non-target</i> do segundo grupo.	44
Figura 5.3 –Sinais <i>target</i> e <i>non-target</i> do terceiro grupo.	45
Figura 5.4 –Sinais <i>target</i> e <i>non-target</i> do quarto grupo.	46
Figura 5.5 –Influência do maior pico na detecção do P300.	48
Figura 5.6 –Influência do maior vale na detecção do P300.	48
Figura 5.7 –Influência do valor da área na detecção do P300.	49
Figura 5.8 –Influência do valor RMS na detecção do P300.	49
Figura 5.9 –Taxas de acertos de símbolos da ICM baseada em parâmetros P300.	52
Figura 5.10 –Taxas de transferência de informação da ICM baseada em parâmetros P300.	52
Figura 5.11 –Taxas de acertos da ICM baseada na forma de onda.	55
Figura 5.12 –Taxas de transferência de informação da ICM baseada na forma de onda.	55

Lista de tabelas

Tabela 4.1 –Voluntários submetidos ao protocolo experimental.	28
Tabela 4.2 –Resumo das características baseadas em parâmetros P300.	31
Tabela 5.1 –Resultados de detecção da ICM baseada em parâmetros P300 para $N_{ep} = 15$	50
Tabela 5.2 –Resultados de detecção da ICM baseada na forma de onda para $N_{ep} = 15$	53
Tabela 6.1 –Comparação de diferentes ICM Baseadas em P300.	59

Lista de abreviaturas e siglas

ELA	Esclerose Lateralizada Amiotrófica
ALS	<i>Amyotrophic Lateral Sclerosis</i>
EMG	Eletromiograma
ICM	Interface Cérebro-Máquina
P300	Potencial relacionado a evento registrado no escalpo através de eletroencefalograma
SNR	Relação Sinal-Ruído (do inglês <i>Signal-to-Noise Ratio</i>)
PRE	Potencial Relacionado a Evento
EEG	Eletroencefalograma
PFC	Projeto Final de Curso
NEPEB	Núcleo de Ensino e Pesquisa em Engenharia Biomédica
EPSP	Potencial Excitatório Pós-Sináptico (do inglês <i>Excitatory Post-Synaptic Potential</i>)
IPSP	Potencial Inibitório Pós-Sináptico (do inglês <i>Inhibitory Post-Synaptic Potential</i>)
EOG	Eletrooculograma
ECG	Eletrocardiograma
MRCP	Potenciais Corticais Relacionados ao Movimento (do inglês <i>Movement-Related Cortical Potentials</i>)
CNV	Variação Negativa Contingente (do inglês <i>Contingent Negative Variation</i>)
PINV	<i>Postimperative Negative Variation</i>
VEP	Potencial Evocado Visual (do inglês <i>Visual Evoked Potential</i>)
MEG	Magnetoencefalografia
PET	Tomografia por Emissão de Pósitrons

fMRI	Ressonância Magnética Funcional
fNIRS	Espectroscopia de Infra-Vermelho Próximo Funcional
CAR	Referência à Média dos Eletrodos (do inglês <i>Common Average Referencing</i>)
ICA	Análise de Componentes Independentes (do inglês <i>independent component analysis</i>)
ErrP	(<i>Error-related Potentials</i>)
PCA	Análise de Componentes Principais (do inglês <i>Principal Component Analysis</i>)
LDA	Análise Discriminante Linear (do inglês <i>Discriminant Linear Analysis</i>)
RCP	Paradigma Linha-Coluna (do inglês <i>row-column paradigm</i>)
ITI	Intervalo Entre Tentativas (do inglês <i>inter-trial interval</i>)
IIE	Intervalo de Intensificação
INI	Intervalo de Não Intensificação
ISI	Intervalo Entre Estímulos (do inglês <i>inter-stimulus interval</i>)
LARS	(<i>Least Angle Regression</i>)
SVR	Regressor de Vetores de Suporte(do inglês <i>support vector regression</i>)
SVM	Máquina de Vetores de Suporte(do inglês <i>support vector machine</i>)

Lista de símbolos

δ	Banda do eletroencefalograma compreendida entre $0.1 - 3.5Hz$;
θ	Banda do eletroencefalograma compreendida entre $4 - 7.5Hz$;
α	Banda do eletroencefalograma compreendida entre $8 - 13Hz$;
β	Banda do eletroencefalograma compreendida entre $14 - 30Hz$;
γ	Banda do eletroencefalograma que compreende frequências $> 30Hz$;
$PPeak$	Amplitude do maior pico pós-estímulo
$PLat$	Latência de ocorrência do maior pico pós-estímulo
$NPeak$	Amplitude do maior vale pós-estímulo
$NLat$	Latência de ocorrência do maior vale pós-estímulo
$Area$	Valor da área entre o maior vale e o maior pico pós-estímulo
RMS	Valor RMS entre o maior vale e o maior pico pós-estímulo
A_s	Taxa de acertos de símbolos da ICM
T_B	Taxa de transferência de informação da ICM
B	Número de <i>bits</i> transmitidos por tentativa
t_{sel}	Tempo de seleção do símbolo

Sumário

1	Introdução	1
	<i>Este capítulo apresenta a motivação e justificativa para a realização deste projeto e o local de desenvolvimento, bem como descreve brevemente a estrutura da monografia.</i>	
1.1	Motivação e Justificativa	1
1.2	Objetivos	3
1.3	Local de Realização	4
1.4	Estrutura da Monografia	4
2	Eletroencefalografia e Potenciais Relacionados a Evento	5
	<i>Este capítulo apresenta uma revisão bibliográfica sobre eletroencefalografia e potenciais relacionados a evento, especialmente o potencial P300, focando na descrição de princípios fisiológicos.</i>	
2.1	O Eletroencefalograma Espontâneo	5
2.2	O Sistema Internacional 10-20	7
2.3	Artefatos	8
2.4	Potenciais Relacionados a Evento	8
2.5	Modelo do PRE e a Média Coerente	11
2.6	O Potencial P300	12
3	Interfaces Cérebro-Máquina	14
	<i>Este capítulo apresenta uma revisão bibliográfica sobre Interface Cérebro-Máquina, contendo o estado da arte em aplicações e técnicas de processamento de sinais.</i>	
3.1	Conceitos e Definições	14
3.2	Estrutura Geral de uma ICM	15
3.3	Técnicas de Processamento de Sinais Aplicadas em ICM	17
3.3.1	Pré-processamento	17
3.3.2	Extração de Características	18
3.3.3	Seleção de Características	20
3.3.4	Classificação de Características	21
3.3.5	Pós-processamento	23
3.4	ICM Baseadas em P300 e Aplicações	23
4	Metodologia	27
	<i>Este capítulo apresenta a metodologia empregada na realização do projeto. São apresentados o protocolo experimental e as técnicas de processamento de sinais</i>	

utilizadas. A condução dos testes e os procedimentos de análise dos resultados são brevemente descritos.

4.1	Participantes e Aquisição dos Sinais Eletroencefalográficos	27
4.2	Protocolo Experimental	29
4.3	Processamento dos Sinais	30
4.3.1	Pré-processamento	30
4.3.2	Extração e Seleção de Características	30
4.3.3	Classificação a Partir dos Valores da Função de Regressão do <i>Support Vector Regression</i>	34
4.4	Avaliação de Desempenho da ICM	39
4.4.1	Taxa de Acertos	39
4.4.2	Taxa de Transferência de Informação	40
4.4.3	Análise Estatística	41
5	Resultados	42
	<i>Este capítulo apresenta os resultados da análise dos potenciais P300 e do desempenho da ICM implementada.</i>	
5.1	Formas de Onda dos Potenciais P300	42
5.2	Desempenho da ICM Baseada em Parâmetros P300	47
5.2.1	Parâmetros Extraídos dos Potenciais P300	47
5.2.2	Taxa de Acertos	50
5.2.3	Taxa de Transferência da Informação	52
5.3	Desempenho da ICM Baseada na Forma de Onda	53
5.3.1	Taxa de Acertos	53
5.3.2	Taxa de Transferência de Informação	55
5.4	Comparação Estatística do Desempenho das ICM	55
6	Discussão	56
	<i>Este capítulo discute os resultados obtidos, comparando-os com os objetivos iniciais estabelecidos e com trabalhos similares.</i>	
6.1	Avaliação das Formas de Onda e Parâmetros dos Potenciais P300	56
6.2	Desempenho das ICM Desenvolvidas	57
6.3	Comparação com Resultados da Literatura	58
6.4	Análise dos Objetivos do Projeto Final de Curso	59
7	Conclusão	61
	<i>Este capítulo apresenta as conclusões finais do projeto, bem como sugestões de trabalhos futuros.</i>	
	Referências	63

1 Introdução

Este capítulo apresenta a motivação e justificativa para a realização deste projeto e o local de desenvolvimento, bem como descreve brevemente a estrutura da monografia.

1.1 Motivação e Justificativa

A esclerose lateral amiotrófica (ELA) – *Amyotrophic Lateral Sclerosis (ALS)*, no inglês – é uma doença neurodegenerativa, que atinge principalmente o sistema motor. À medida que a doença evolui, ocorre o comprometimento físico progressivo e cumulativo em pacientes, o que leva à eventual morte devido à falha dos músculos respiratórios (OLIVEIRA; PEREIRA, 2009).

A ELA atinge pessoas de todo o mundo, de todas as etnias e classes socioeconômicas¹. *Lou Gehrig*, um famoso jogador de *baseball* americano, foi um dos primeiros pacientes diagnosticados com ELA – motivo pelo qual é popularmente conhecida como *doença de Lou Gehrig*. O famoso cientista e físico *Stephen Hawking* é outra pessoa que sofre de ELA. *Hawking* é considerado uma exceção entre os casos da doença, pois é o único paciente registrado que sobreviveu por mais de 40 anos após o diagnóstico.

Atualmente, as causas da ELA ainda não são completamente compreendidas, nem os seus mecanismos de evolução. A doença possui diversas origens e formas de evolução, não existindo meios efetivos para tratamento, muito menos uma cura².

A prevalência da ELA é de 2 para cada 100000 pessoas. Aproximadamente 5600 pessoas são diagnosticadas com ELA por ano nos Estados Unidos³. Após o diagnóstico, a expectativa de vida média é de 5 anos, o que leva a um total de 30000 pessoas com esta disfunção neste país. No Brasil, estima-se que 20000 brasileiros apresentem esta doença atualmente.

Muitos estudos tem sido realizados no sentido de prolongar a expectativa de vida pós-diagnóstico. Entretanto, a melhoria da qualidade de vida dos pacientes é ainda um grande desafio, abrangendo aspectos que vão desde o auxílio respiratório até a melhoria dos mecanismos utilizados pelo paciente para se comunicar com a equipe de tratamento e com sua própria família (OLIVEIRA; PEREIRA, 2009).

¹ <http://www.alsa.org/about-als/facts-you-should-know.html>

² <http://www.abrela.org.br>

³ http://www.ninds.nih.gov/disorders/amyotrophiclateralsclerosis/detail_ALS.htm

Além da ELA, outras doenças ou desordens, tais como acidente vascular encefálico, lesão cerebral ou medular, paralisia cerebral, distrofias musculares e esclerose múltipla, prejudicam severamente os caminhos neurais utilizados para controlar os músculos. Em alguns casos, os próprios músculos são afetados por estas doenças (WOLPAW *et al.*, 2002). Nestas condições, existem três métodos para auxiliar no controle motor comprometido.

O primeiro método consiste em aumentar as capacidades dos caminhos neurais restantes, substituindo as funções dos músculos paralisados por aqueles que ainda conseguem ser controlados pelo paciente. Um exemplo é o uso do movimento dos olhos para responder a questões ou efetuar simples comandos (LACOURSE; JR., 2002).

O segundo método visa restaurar as funções de músculos paralisados, atribuindo seu controle a eferências originalmente associadas a outros músculos. Assim, o registro de eletromiograma (EMG) acima do nível da lesão, por exemplo, pode ser usado para controlar a contração dos músculos afetados (KILGORE *et al.*, 1997).

O terceiro método – por vezes o único aplicável em casos de perdas motoras severas ou em estágios avançados das disfunções – se baseia no estabelecimento de um novo canal de comunicação e controle por meio do cérebro (WOLPAW *et al.*, 2002).

Os dispositivos que implementam este último método são conhecidos como interfaces cérebro-máquina (ICM), sendo capazes de permitir que seus usuários se comuniquem com o ambiente fazendo uso da atividade cerebral. Desta maneira, ICM são sistemas de comunicação pelos quais uma pessoa pode enviar mensagens ou comandos através de um caminho diferente daquele fornecido por nervos periféricos e músculos (WOLPAW *et al.*, 2002).

No contexto das doenças neurodegenerativas como a ELA, bem como das outras desordens citadas, as ICM apresentam-se como solução para aumentar a autonomia, levando, portanto, a uma melhoria da qualidade de vida dos pacientes.

As pessoas que sofrem com estas doenças e desordens são aquelas que se beneficiarão de forma mais imediata com o uso de ICM. Dentre as aplicações que têm sido relatadas, pode-se citar o controle de próteses, cadeiras de rodas motorizadas, automação residencial, navegação de *browsers* e auxílio à digitação (SELLERS *et al.*, 2006).

A somatória destes fatores permite concluir que, com a efetiva participação de profissionais de vários campos, as ICM poderão, em um futuro próximo, fornecer soluções sofisticadas de comunicação e controle para pessoas com deficiências motoras. Além disso, mesmo as pessoas sem deficiências poderão se beneficiar de ICM, contextualizadas como um canal suplementar de controle e interação com o ambiente (WOLPAW *et al.*, 2002).

Neste contexto, as ICM podem ser classificadas em sete categorias diferentes, de acordo com o tipo de atividade em que se baseiam: atividade sensório-motora, potenciais evocados visuais transitórios, potenciais evocados em regime permanente, atividades de células neurais, resposta a tarefas mentais (imagética motora), P300 e sinais híbridos (mais de um tipo de sinal / potencial cerebral) (BASHASHATI *et al.*, 2007).

ICM baseadas em P300 são uma abordagem promissora para pacientes com deficiências motoras, principalmente ELA. Comparadas a dispositivos assistivos baseados em respostas musculares (KILGORE *et al.*, 1997), estas ICM apresentam taxas de comunicação mais baixas. Entretanto, elas representam uma alternativa muito útil para pacientes cujo estágio de deficiência motora impossibilita o uso de outros biosinais com melhor razão sinal-ruído (SNR, do inglês *signal-to-noise ratio*), motivo pelo qual têm sido alvo de intensas pesquisas (MCFARLAND *et al.*, 2011).

O P300 é um potencial relacionado a evento (PRE) registrado no escalpo através do eletroencefalograma (EEG), que surge como resposta a estímulos visuais, auditivos ou somatosensoriais, quando existe a alternância de estímulos de interesse – ocorrência rara ou infrequente – e rotineiros. Este potencial é registrado com maior evidência na região centro-parietal do córtex e apresenta um pico positivo em cerca de 300ms pós-estímulo (ALLISON; PINEDA, 2003).

O desafio na utilização do P300 como atividade base de uma ICM consiste na sua detecção, devido ao seu mascaramento pela atividade espontânea (EEG de fundo ou espontâneo). Para contornar este obstáculo, utilizam-se diversas técnicas de processamento de sinais, que são empregadas com objetivo de remover artefatos, aumentar a SNR e extrair características do sinal (MASON; BIRCH, 2003).

1.2 Objetivos

Dada a importância das ICM para a melhoria da qualidade de vida de pacientes com comprometimento motor, este Projeto Final de Curso (PFC) terá os seguintes objetivos:

1. Avaliar a variabilidade inter-individual do P300;
2. Identificar um conjunto de características capaz de identificar com elevada taxa de acertos a ocorrência do P300;
3. Investigar técnicas de processamento de sinais que possam ser empregadas na detecção do P300;

4. Elaborar um algoritmo de detecção do P300 adequado para aplicação em uma ICM do tipo soletrador (*speller*);
5. Avaliar o algoritmo de detecção proposto e a ICM desenvolvida, validando-os com sinais reais.

1.3 Local de Realização

Este Projeto Final de Curso será realizado no Laboratório de Engenharia Biomédica (LEB), utilizando os equipamentos e infra-estrutura oferecidos. O LEB, está associado ao NEPEB ⁴ (Núcleo de Estudos e Pesquisa em Engenharia Biomédica), que é um grupo de pesquisa da Universidade Federal de Minas Gerais cadastrado no Diretório de Grupos do CNPq e que conta com a participação de diversos pesquisadores e alunos de graduação e pós-graduação. O Núcleo tem como foco a investigação principalmente nas áreas de Processamento de Sinais Biomédicos e Instrumentação Biomédica.

1.4 Estrutura da Monografia

A monografia está dividida em 7 capítulos. O presente, [Capítulo 1](#), apresentou a motivação e objetivos do trabalho. O [Capítulo 2](#) faz uma breve revisão sobre princípios de eletroencefalografia e potenciais relacionados a evento, focando no sinal P300. No [Capítulo 3](#), alguns aspectos relacionados a ICM são introduzidos em maior detalhe. O protocolo experimental e a metodologia de processamento de sinais são descritos no [Capítulo 4](#). O [Capítulo 5](#) relata os principais resultados, que são discutidos posteriormente no [Capítulo 6](#). Por fim, apresenta-se as considerações finais e as sugestões de trabalhos futuros no [Capítulo 7](#).

⁴ <http://www.cpdee.ufmg.br/~nepeb>

2 Eletroencefalografia e Potenciais Relacionados a Evento

Este capítulo apresenta uma revisão bibliográfica sobre eletroencefalografia e potenciais relacionados a evento, especialmente o potencial P300, focando na descrição de princípios fisiológicos.

2.1 O Eletroencefalograma Espontâneo

O eletroencefalograma (EEG) é o registro da soma espaço-temporal de potenciais elétricos gerados a partir de potenciais pós-sinápticos de neurônios encefálicos (DIE-TRICH; KANSO, 2010).

Esta é uma técnica não-invasiva, sendo os sinais coletados no escalpo. As correntes iônicas passam pelas meninges, pelos ossos do crânio e pela pele, até chegar aos eletrodos. Por isso, os sinais elétricos são fortemente atenuados, o que torna necessário o uso de amplificadores de alto ganho para possibilitar a aquisição destes sinais (TEPLAN, 2002).

A amplitude do EEG costuma atingir no máximo $100\mu V$ e sua banda de frequência abrange de 0, 1 a $100Hz$. Comumente, o EEG é dividido em cinco bandas (NIEDERMEYER; SILVA, 2004):

- Banda δ : $0,1 - 3,5Hz$;
- Banda θ : $4 - 7,5Hz$;
- Banda α : $8 - 13Hz$;
- Banda β : $14 - 30Hz$;
- Banda γ : $> 30Hz$.

Atividades nestas diferentes bandas podem ser visualizadas na [Figura 2.1](#).

A banda δ apresenta os maiores valores de EEG, sendo a faixa com potência predominante em crianças e no sono profundo de adultos. A banda θ está presente no sono leve e na vigília (NIEDERMEYER; SILVA, 2004).

A banda γ pode ser encontrada durante diferentes condições comportamentais e experimentais que envolvem processamento sensorial e/ou cognitivo. Seus primeiros




Figura 2.1 – Bandas do EEG. Adaptado de: en.wikipedia.org.

registros apareceram com o advento da eletroencefalografia digital, uma vez que os equipamentos de EEG analógico convencionais eram dedicados a gravar frequências menores que 25Hz ([HUGHES, 2008](#)).

A banda α , também conhecida como ritmo α , é melhor observada nas regiões posteriores, apresentando uma amplitude típica de $50\mu\text{V}$. O fechamento dos olhos e o relaxamento resultam no aumento de amplitude desse ritmo. Entretanto, quando a pessoa abre os olhos ou entra em estado de alerta, como durante a realização de um cálculo, sua amplitude é reduzida, tornando a aumentar assim que os olhos são novamente fechados. Assim como a banda γ , a banda β tem sido observada em diferentes condições experimentais e costuma apresentar amplitude menor que $30\mu\text{V}$ ([TEPLAN, 2002](#)).

O EEG espontâneo ou de fundo, aquele registrado na condição de não-estimulação, se constitui em um sinal aleatório, não apresentando padrões de forma de onda facilmente identificáveis como outros biosinais (e.g.: complexo QRS do ECG) ([MELGES; Sá; IN-](#)

FANTOSI, 2012).

Embora essa característica dificulte a inspeção visual, o EEG é amplamente utilizado nos campos de neurofisiologia e neurologia clínica. Em grande parte das aplicações, técnicas de processamento são empregadas para facilitar sua interpretação.

2.2 O Sistema Internacional 10-20

O Sistema Internacional 10-20 (Figura 2.2) é um padrão de posicionamento de eletrodos no escalpo para a gravação do EEG, originalmente proposto por Jasper (1958). De acordo com esse padrão, são colocados 21 eletrodos na superfície craniana. O posicionamento utiliza as seguintes referências: o *nasion*, que é a depressão acima do nariz, e o *inion*, que é a protuberância na base do crânio.

Os eletrodos são posicionados em intervalos de 10 e 20% das distâncias *nasion-inion* pelos planos mid-sagital e transversal, bem como da distância entre lóbulos auriculares.

Cada derivação é nomeada com uma letra e um número. As letras identificam as seguintes regiões: frontopolar (Fp), frontal (F), central (C), temporal (T), parietal (P), occipital (O) e auricular (A). As derivações sobre a linha média são indicadas com a letra "Z" (MELGES, 2009). Números pares indicam o hemisfério direito, e números ímpares indicam o hemisfério esquerdo.




Figura 2.2 – Sistema Internacional 10-20 para posicionamento de eletrodos do EEG. Adaptado de: en.wikipedia.org e (NIEDERMEYER; SILVA, 2004)

2.3 Artefatos

A coleta do EEG é corrompida pela presença de outros sinais elétricos, provenientes de diversas fontes. Qualquer ruído presente na aquisição que interfira na interpretação do EEG é denominado artefato, o qual é geralmente classificado em três categorias, de acordo com sua origem: extrínseco, instrumental e fisiológico (SAUNDERS, 1979).

Artefatos extrínsecos são causados por: interferências das linhas de alimentação, tais como os ruídos eletromagnéticos oriundos dos harmônicos fundamentais da rede; equipamentos ligados no paciente, como ventiladores; equipamentos presentes no ambiente, como lâmpadas, aquecedores, aparelhos de ar condicionado e outros (KLASS, 1995). Geralmente, este tipo de artefato só pode ser reduzido com o uso de blindagem.

O mal funcionamento dos eletrodos ou suas conexões, as interferências dos próprios componentes dos equipamentos de aquisição de sinais – tais como amplificadores, chaves e osciladores –, bem como outras características dos instrumentos utilizados na coleta do EEG são responsáveis pela geração dos artefatos de origem instrumental (KLASS, 1995).

Fontes fisiológicas de artefatos incluem movimentos musculares, eletrocardiograma (ECG), eletrooculograma (EOG), pulsação e movimentos espontâneos do paciente. O EOG merece destaque especial, visto que sua fonte está muito próxima dos eletrodos utilizados para o registro do EEG. Enquanto o EEG apresenta magnitude da ordem de dezenas de microvolts, o ECG e o EOG apresentam magnitudes da ordem de milivolts, distorcendo fortemente o sinal (NOLAN; WHELAN; REILLY, 2010).

2.4 Potenciais Relacionados a Evento

Potenciais relacionados a evento (PRE) são sinais elétricos, medidos através do EEG como resultado direto de eventos sensoriais, cognitivos ou motores, tais como: audição de tons específicos, visualização de imagens, leitura de palavras e pressionamento de botões (BLACKWOOD, 1990).

São caracterizados como uma resposta eletrofisiológica ao estímulo com forma de onda específica. Isto implica que a forma de onda do PRE não se modifica significativamente com o tempo, apresentando padrão similar de estímulo para estímulo (SUR; SINHA, 2009).

Atualmente, considera-se que os PRE são produzidos quando um grande número de neurônios corticais similarmente orientados disparam sincronicamente com o processamento de informação de um dado estímulo (PETERSON C. E. SCHROEDER, 1995).

Comumente, os PRE são divididos em duas categorias. Os componentes que apresentam picos dentro dos primeiros 100ms pós-estímulo são denominados PRE *exógenos* ou *sensoriais*, por dependerem fortemente das características físicas do estímulo. PRE que apresentam picos depois de 100ms pós-estímulo são denominados *endógenos* ou *cognitivos* e, usualmente envolvem processamento por áreas corticais associativas e, portanto, apresentam maior variabilidade (SUR; SINHA, 2009).

As amplitudes de PRE variam de $1\mu\text{V}$ a $10\mu\text{V}$, o que é uma ordem de grandeza menor que a amplitude do EEG. Esta característica dificulta a detecção dos PRE em meio à atividade cerebral de fundo (NIEDERMEYER; SILVA, 2004).

A forma de onda de um PRE consiste na presença de picos ou vales característicos, nomeados, respectivamente, com as letras "P" ou "N", indicando deflexão de tensão positiva ou negativa, sendo também comum indicar a latência, em ms , de ocorrência do pico/vale, como no caso do P300 (LUCK, 2005).

A Figura 2.3 exemplifica a forma de onda de um PRE, com vários componentes enumerados. Nota-se a inversão do eixo vertical, uma prática comum na representação de PRE advinda da literatura médica.




Figura 2.3 – Forma de onda típica de PRE. Adaptado de: en.wikipedia.org.

Alguns exemplos de PRE incluem (SUR; SINHA, 2009):

- **P50:** é o maior pico positivo entre 40ms e 75ms pós-estímulo, cuja amplitude é calculada como a diferença entre o ponto mais positivo neste intervalo e ponto mais negativo anterior. Ocorre em condições em que um indivíduo direciona sua atenção para estímulos de interesse e ignora estímulos de fundo, ou seja, condições de demanda por atenção seletiva. O P50 é normalmente eliciado através de paradig-

mas com cliques repetitivos ou tons em regime permanente, normalmente por via auditiva;

- **N100/N1:** é o maior vale que ocorre entre 90ms e 200ms pós-estímulo, observado quando há ocorrência de um estímulo desviante;
- **P200/P2:** é o maior pico que ocorre entre 100 e 250ms pós-estímulo e comumente surge associado ao N100 formando o componente N1/P2.
- **N200/N2:** é o maior vale que ocorre cerca de 200ms pós-estímulo, sendo eliciado por qualquer mudança discriminável em uma estimulação auditiva repetitiva.
- **N300:** PRE recentemente descoberto, é elicitado no contexto de congruência e expectativa semântica;
- **N400:** vale que aparece entre 300 a 600ms pós-estímulo, relacionado ao contexto de incongruência semântica (e.g.: estímulo por leitura de frases como "A vovó comeu o chinelo");
- **P600:** PRE que aparece no contexto de processamento de linguagem quando uma sentença possui uma violação sintática, tem uma estrutura sintática não usual ou apresenta uma estrutura sintática complexa;
- **MRCP:** potenciais corticais relacionados a movimento (MRCP, do inglês *movement-related cortical potentials*) são uma série de potenciais que ocorrem em instantes de tempo próximos a atividades relacionadas ao movimento. Podem ocorrer antes, durante ou depois do movimento, e estão associados ao estado de prontidão do córtex para execução do movimento;
- **CNV (*Contingent Negative Variation*):** o contingente de variação negativa foi um dos primeiros PRE descobertos, e pode ser eliciada por um protocolo padrão de tempo de reação de resposta motora. Um estímulo inicial (S1) serve como um sinal preparatório para um estímulo de ação (S2), ao qual o indivíduo deve responder. A CNV pode aparecer no início ou final do intervalo entre os dois estímulos. Quando aparece no início, é um indicativo de processos excitatórios, enquanto a CNV no final do intervalo indica atenção à tarefa sendo executada;
- **PINV (*Postimperative Negative Variation*):** é o atraso na determinação do CNV, e indica atividade cognitiva sustentada;
- **P300:** detalhado na [seção 2.6](#), é o PRE sobre o qual mais pesquisas foram realizadas até hoje.

2.5 Modelo do PRE e a Média Coerente

Para derivar um modelo do PRE, assume-se que sua forma de onda permanece inalterada entre sucessivas apresentações do estímulo, e que a atividade cerebral de fundo (EEG de fundo), pode ser modelada como um ruído aditivo de média $\mu = 0$ (NIEDERMEYER; SILVA, 2004). A partir destas premissas, podemos representar o PRE por um modelo aditivo, esquematizado na Figura 2.4, onde $x[n]$ é o estímulo apresentado para eliciar o PRE $s[n]$; $h[n]$ é a função de transferência do sistema, correspondente aos processos cerebrais; $v[n]$ é o EEG de fundo; $y[n]$ é o sinal medido (NIEDERMEYER; SILVA, 2004; MELGES, 2009).




Figura 2.4 – Modelo do PRE. Adaptado de (MELGES, 2009).

Utilizando-se o modelo do PRE apresentado, pode-se representar a i -ésima época do sinal medido (NIEDERMEYER; SILVA, 2004):

$$y_i[n] = s[n] + v_i[n] \quad (2.1)$$

Observa-se que $s[n]$ não varia com a época, e por isso o índice i foi omitido.

Como o EEG espontâneo apresenta amplitudes muito maiores que o PRE, faz-se necessária a adoção de métodos para aumentar a SNR. Uma das técnicas mais frequentemente utilizadas é a média coerente, um procedimento que realiza a média de várias épocas do EEG, sincronizadas pelo instante de estimulação.

A partir da Equação 2.1, a realização da média coerente fornecerá:

$$\hat{s}[n] = \frac{1}{M} \sum_{i=1}^M y_i[n] = \frac{1}{M} \sum_{i=1}^M s[n] + \frac{1}{M} \sum_{i=1}^M v_i[n], \quad (2.2)$$

onde $\hat{s}[n]$ é um estimador da resposta ao estímulo; M é o número de épocas do EEG utilizadas para o cálculo.

Como $\nu[n]$ apresenta média zero, o segundo somatório tenderá a zero quando M aumentar, aproximando o estimador $\hat{s}[n]$ do real valor da resposta ao estímulo, isto é, o PRE de interesse.

2.6 O Potencial P300

O potencial P300 é um componente descoberto por [Sutton et al. \(1965\)](#) e, desde sua descoberta, tem sido o PRE sobre o qual mais estudos foram realizados, notadamente em duas grandes áreas: i) interfaces cérebro-máquina; ii) detecção de informações ocultas, sobretudo em pesquisas para substituição do polígrafo.

É caracterizado como um pico de tensão de 2 a $5\mu V$, ocorrendo de 300 a $600ms$ pós-estímulo. Origina-se nas regiões frontal e temporo-parietal, apresentando maior amplitude sobre as derivações Fz, Cz e Pz. Tipicamente, a amplitude cresce da região frontal até a parietal ([POLICH, 2007](#)).

Apesar da amplitude do P300 ser máxima na região parietal, a maior associação entre amplitude e latência é encontrada sobre a região frontal ([POLICH, 1997](#)).

Atualmente, considera-se que a latência do P300 é inversamente proporcional à velocidade de classificação do estímulo, após a discriminação de diferentes tipos de eventos. Deste modo, considera-se que latências menores indicam uma performance mental de classificação superior, quando comparadas a latências maiores. A amplitude do P300 é um indicativo da atenção do indivíduo ao estímulo, sendo mais elevada quanto maior a atenção ao estímulo apresentado ([SUR; SINHA, 2009](#)).

A eliciação do P300 ocorre quando uma pessoa foca a atenção em um símbolo de interesse (*target*), que é apresentado de forma infrequente e intercalada com símbolos não significativos (*non-target*), mas que possuem maior frequência de apresentação ([ROSENFELD, 2011](#)).

O P300 possui uma natureza dual, passiva e ativa. Pode ser eliciado ativamente pela atenção voluntária da pessoa ao estímulo, ou passivamente por propriedades perceptuais de baixo nível ([COMERCHERO; POLICH, 1999](#)). De acordo com a natureza de eliciação, apresenta variações na sua amplitude e latência, sendo dividido em duas subcomponentes: a primeira, de natureza passiva, é denominada P3a; a segunda, de natureza ativa e dependente da atenção, é denominada P3b ([POLICH, 2007](#)). Para aplicações de ICM, a subcomponente P3b apresenta papel preponderante.

Como todo PRE, a SNR do P300 é muito baixa, sendo necessário calcular a média

coerente de diversas épocas do EEG para conseguir visualizar sua forma de onda. A Figura 2.5 exemplifica a forma de onda do P300 para sinais *target* e *non-target*.




Figura 2.5 – Exemplo do sinal P300.

3 Interfaces Cérebro-Máquina

Este capítulo apresenta uma revisão bibliográfica sobre Interface Cérebro-Máquina, contendo o estado da arte em aplicações e técnicas de processamento de sinais.

3.1 Conceitos e Definições

Uma ICM é um sistema integrado de *hardware* e *software* que permite aos seus usuários o controle de ambientes ou dispositivos, fazendo uso da atividade cerebral para tal fim (NICOLAS-ALONSO; GOMEZ-GIL, 2012).

As mensagens enviadas pela ICM com base na atividade cerebral são utilizadas para executar ações. Portanto, não há apenas a detecção, mas também a interpretação e tradução dos sinais neurais em comandos (WOLPAW *et al.*, 2002).

A atividade cerebral na qual se baseiam as ICM pode ser monitorada de diversas maneiras: magnetoencefalografia (MEG), tomografia por emissão de pósitrons (PET), ressonância magnética funcional (fMRI), espectroscopia de infra-vermelho próximo funcional (fNIRS) e EEG (WOLPAW *et al.*, 2002). As principais aplicações de ICM utilizam o EEG, porque é uma técnica que oferece boa qualidade de sinal, ao mesmo tempo em que apresenta baixo custo e facilidade de operação. Apresenta, ainda, alta resolução temporal, fundamental para que rápidas taxas de comunicação possam ser alcançadas (NICOLAS-ALONSO; GOMEZ-GIL, 2012).

Há duas grandes classes de ICM: dependentes e independentes. ICM dependentes são aquelas que prescindem da manutenção de determinadas funções (e.g.: motoras) para o seu correto funcionamento, como por exemplo as interfaces baseadas em potenciais evocados visuais (VEP, do inglês *visual evoked potential*). Tais ICM dependem da integridade dos músculos extra-oculares para o direcionamento do olhar (ELSHOUT; MOLINA, 2009). Por outro lado, tem-se as ICMs independentes, tais como aquelas baseada no P300, cuja geração depende mais fortemente da intenção do usuário do que da orientação precisa dos olhos (FABIANI *et al.*, 1987). Estima-se que as ICM independentes serão mais úteis para pessoas com distúrbios neuromusculares severos, já que não necessitam do perfeito funcionamento dos nervos periféricos e músculos (WOLPAW *et al.*, 2002).

Existem três potenciais grupos de usuários de ICM: pessoas que perderam toda a atividade motora, devido à ALS, por exemplo; pessoas que apresentam movimento apenas residual, como movimento dos olhos ou lábios; e pessoas que não apresentam déficit motor (NICOLAS-ALONSO; GOMEZ-GIL, 2012). Atualmente, as pessoas que se enquadram no

primeiro ou segundo grupos são os principais candidatos a uso contínuo de ICM. Embora as taxas de comunicação relatadas na literatura ainda sejam baixas, a severidade das desordens apresentadas por essas pessoas faz com que as ICM sejam uma alternativa viável (NICOLAS-ALONSO; GOMEZ-GIL, 2012).

Entretanto, a maioria das aplicações desenvolvidas até hoje tem como foco treinamento ou demonstração. Apesar dos recentes avanços, o desenvolvimento de ICM encontra grandes desafios que devem ser superados para efetivar seu uso de forma contínua (MORE, 2003):

- Aumentar as taxas de transferência de informação das ICM, promovendo melhoria na interação com dispositivos e o ambiente;
- Diminuir as taxas de erro de classificação, que frustram o usuário e complicam as interações;
- Promover maior autonomia dos usuários da ICM no que concerne a aplicação de eletrodos e configuração dos dispositivos eletrônicos, hoje realizadas por auxiliares;
- Criar métodos que possibilitem ligar a ICM automaticamente;
- Diminuir a carga cognitiva necessária para operação de ICM, de modo a possibilitar seu uso fora de ambientes de laboratório.

As diversas aplicações de ICM poderão fornecer um mecanismo para aumentar a qualidade de vida destas pessoas. Por exemplo a redução da necessidade de cuidados e dos seus custos auxiliará a vida dos parentes e da própria pessoa (NICOLAS-ALONSO; GOMEZ-GIL, 2012). Porém, os desafios existentes fazem com que o desenvolvimento de ICM seja uma tarefa complexa (WOLPAW *et al.*, 2002).

3.2 Estrutura Geral de uma ICM

A estrutura geral de uma ICM que usa EEG é composta pelos componentes esquematizados na Figura 3.1.

Para converter os estados cerebrais do usuário em sinais elétricos, são afixados *eletrodos* na superfície do escalpo, de modo a coletar as assinaturas neurais através do EEG. O sinal dos eletrodos é encaminhado até o *amplificador*, que tem como função condicionar o sinal para uma faixa de tensão adequada às etapas posteriores (MASON; BIRCH, 2003).

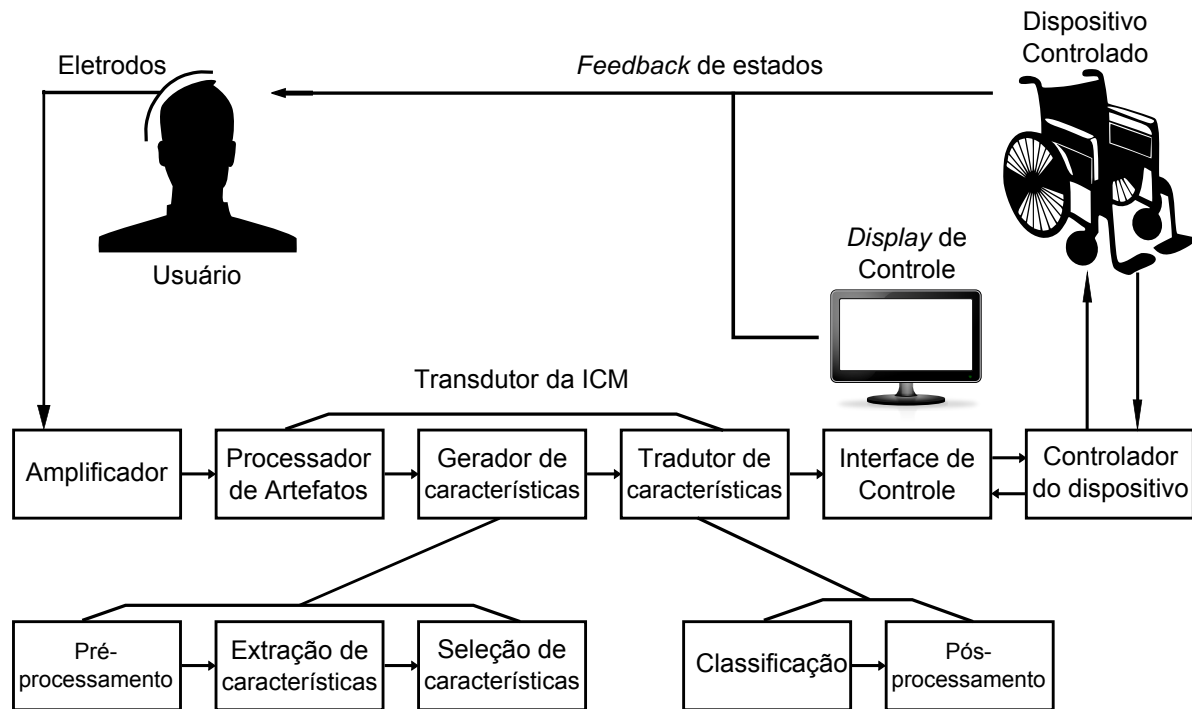


Figura 3.1 – Estrutura geral de uma BCI. Adaptado de (BASHASHATI *et al.*, 2007).

Depois de amplificados, os sinais coletados chegam ao *processador de artefatos*. Este componente da ICM tem como objetivo reduzir ou eliminar os artefatos presentes no sinal coletado, utilizando, por exemplo, filtros analógicos (NIEDERMEYER; SILVA, 2004).

Em seguida, o *gerador de características* transforma os sinais coletados em parâmetros que serão utilizadas como base para criação dos mecanismos de controle da ICM. Um exemplo é a geração do espectro de frequência de um sinal, onde a potência espectral das bandas α e β podem ser identificadas e usadas para controle de tarefas (MCFARLAND *et al.*, 2000).

O *gerador de características* é um componente que pode ser subdividido em três etapas. Na etapa de *pré-processamento*, ocorre o emprego de técnicas que visam aumentar a SNR do sinal de entrada. Segue-se a etapa de *extração*, que obtém parâmetros relevantes do sinal. Por fim, a etapa de *seleção* é usada para reduzir o número de parâmetros visando eliminar redundância e diminuir o esforço computacional (maldição da dimensionalidade) (BASHASHATI *et al.*, 2007).

As características geradas nas etapas citadas anteriormente são encaminhadas ao *tradutor de características*. Este bloco pode usar técnicas lineares ou não-lineares, e é subdividido em duas etapas. Na etapa de *classificação*, emprega-se técnicas para trans-

formar as características extraídas dos sinais neurais em sinais lógicos de controle. Por último, a etapa de *pós-processamento* é empregada para diminuir os erros de classificação ou aumentar a taxa de comunicação da ICM (BASHASHATI *et al.*, 2007).

Os sinais lógicos gerados são enviados a uma *interface de controle*, que os transforma em comandos específicos de cada aplicação. Exemplos são os comandos para o acionamento de uma cadeira de rodas motorizada ou uma prótese (direita, esquerda, cima, baixo, etc.), bem como seleções em um programa de computador (clicar, selecionar letra, etc.) (MASON; BIRCH, 2003).

Os comandos gerados são enviados ao *controlador do dispositivo*, o qual pode ser projetado para cada aplicação específica, ou ser uma plataforma de *hardware* e *software* genérica, como um controlador lógico-programável (MASON; BIRCH, 2003).

O *dispositivo controlado* é o último componente da estrutura e abrange uma série de equipamentos que podem ser utilizados conjuntamente com ICM. Exemplos incluem próteses neurais, computadores, sintetizadores de voz, televisores, luzes e outros (WOLPAW *et al.*, 2002).

3.3 Técnicas de Processamento de Sinais Aplicadas em ICM

As próximas seções apresentam uma breve descrição das etapas que compõem os blocos de *geração* e *tradução* de características, apresentando algumas das principais técnicas de processamento de sinais empregadas em cada uma delas.

3.3.1 Pré-processamento

O *pré-processamento* é um estágio que objetiva melhorar a SNR (ALHADDAD *et al.*, 2012).

Filtragem Passa-Faixas

Em grande parte das aplicações de ICM, é empregada uma etapa de filtragem passa-faixas nos sinais coletados. Os valores das frequências de corte do filtro variam de acordo com a banda do componente que deseja-se detectar.

Para o P300, os valores da frequência de corte inferior variam de 0,1 a 1Hz, enquanto os valores da frequência de corte superior vão de 8 a 200Hz. Historicamente, uma faixa de filtragem de 0,02 a 35Hz é utilizada (FARWELL; DONCHIN, 1988). Além do filtro passa-faixas, é comum a inserção de um filtro *notch* na frequência de rede quando esta se encontra dentro da banda de interesse (BOUGRAIN C. SAAVEDRA, 2012).

Entretanto, a largura da banda passante tem diminuído em aplicações mais recentes, abrangendo de 0,1 a 10Hz (LI, 2010), pois testes realizados variando-se a banda passante revelaram que a faixa de 0,1 a 15Hz já é suficiente para proporcionar bons resultados (BOUGRAIN C. SAAVEDRA, 2012).

Referência à Média dos Eletrodos

Os sinais de EEG são usualmente coletados por meio de uma medida diferencial, através do uso de amplificadores de instrumentação. Assim, a seleção do local de posicionamento do eletrodo de referência torna-se um fator importante para a qualidade do registro (ALHADDAD, 2012).

A referência à média dos eletrodos (CAR, do inglês *Common Average Referencing*) é uma técnica que provê uma melhoria na razão sinal-ruído de derivações de EEG.

A média dos valores de todas as derivações é subtraída de cada derivação individual, conforme a Equação 3.1:

$$CAR(V_i) = V_i - \frac{1}{N} \sum_{n=0}^N V_n, \quad (3.1)$$

em que V_i é a derivação de interesse; N é o número de derivações; V_n é a n -ésima derivação afixada no escalpo.

A CAR tem sido considerada a melhor técnica de pré-processamento para detecção do P300 (ALHADDAD *et al.*, 2012). Cabe ressaltar que a referência à média é diferente da referência comum. Nesta outra técnica, os eletrodos são referenciados a um eletrodo comum, tipicamente localizado nos lóbulos auriculares (KRUSIENSKI *et al.*, 2008).

3.3.2 Extração de Características

A *extração de características* é a etapa do processamento responsável por determinar quais são as características de interesse, isto é, aquelas que contém os elementos mais representativos dos sinais coletados. A seguir, alguns parâmetros tipicamente empregados são detalhados.

Valor de Pico

Em ICM que se baseiam em PRE, geralmente utiliza-se como característica o valor de pico do potencial de interesse. Para aquelas baseadas em P300, utiliza-se, em geral, o valor do maior pico que ocorre entre 250 e 500ms pós-estímulo. Exemplos do uso deste

parâmetro podem ser encontrados nos trabalhos de [Farwell e Donchin \(1988\)](#) e [Allison e Pineda \(2003\)](#).

Área Abaixo do Pico

Assim como o cálculo do pico, o valor da área abaixo da componente é frequentemente utilizada como característica de interesse. Uma vantagem deste método é que, além da amplitude, ele incorpora a informação de duração do P300, constituindo-se em um parâmetro com menor variabilidade. Geralmente, o cálculo da área é usado conjuntamente com o cálculo do pico ([XU et al., 2004](#)).

Correlação Cruzada

A correlação cruzada entre dois sinais é uma medida da similaridade entre suas formas de onda, sendo esta medida normalmente fornecida em função de deslocamentos de tempo aplicados a um dos sinais.

A correlação cruzada de dois sinais x e y pode ser calculada matematicamente por 3.2 ([AGUIRRE, 2007](#)):

$$\hat{r}_{xy}(k) = \sum_{m=-\infty}^{m=\infty} x^*[m]y[k+m], \quad (3.2)$$

em que k é o número de deslocamentos de tempo aplicado e $*$ é o complexo conjugado.

Esta análise aplica-se apenas a sinais que possuem média zero. Se este não é o caso, pode-se contornar este problema subtraindo-se a média do sinal.

A análise de correlação cruzada pode ser usada para a detecção do P300 ([BAYLISS; BALLARD, 1999](#)). Inicialmente, um *template* é obtido a partir da média coerente de um número elevado de épocas. Posteriormente, as novas épocas de EEG são correlacionadas com o *template*, gerando a função de correlação.

O valor da correlação no instante de apresentação do estímulo é empregado na diferenciação entre *targets* e *non-targets*. Tal classificação baseia-se na similaridade entre os sinais advindos de novas interações do usuário e o *template* gerado na etapa de treinamento.

Análise de Componentes Independentes

A análise de componentes independentes (ICA, do inglês *Independent Component Analysis*) é um método que objetiva identificar quais são as fontes componentes de um sinal (COMON, 1994). A ICA é usada em vários trabalhos para análise de EEG, buscando separar artefatos da atividade cerebral de interesse. Essa abordagem é baseada no fato de que a atividade cerebral e os artefatos serem processos de origem distinta, o que se reflete em uma independência estatística das componentes (VIGÁRIO *et al.*, 1997; LI, 2010).

Pode-se considerar as derivações x_i do EEG correspondem ao registro de diferentes combinações lineares de n componentes independentes $s_1...s_n$. Desta maneira:

$$x_i = a_{i1}s_1 + a_{i2}s_2 + \dots + a_{in}s_n, \quad (3.3)$$

onde $a_{i1}...a_{in}$ são pesos a serem determinados e x_i e s_n são variáveis aleatórias de média zero (o que pode ser garantido removendo-se o valor médio).

Dentre as classes de algoritmos ICA, pode-se citar como de ampla utilização aqueles que se baseiam na maximização da não-gaussianidade das componentes e os que buscam a minimização da informação mútua entre elas. Alguns dos algoritmos de ICA mais utilizados são o JADE (CARDOSO; SOULOUMIAC, 1993), o Infomax (BELL; SEJNOWSKI, 1995) e o FastICA (HYVARINEN; OJA, 2000).

As séries temporais correspondentes às componentes independentes podem ser usadas como características extraídas do EEG.

3.3.3 Seleção de Características

A *seleção de características* é a etapa do processamento responsável por gerar um subconjunto de características, reduzindo a dimensionalidade dos dados e excluindo características que não são representativas do parâmetro de interesse (BASHASHATI *et al.*, 2007). Além disso, esta etapa reduz sensivelmente o esforço computacional necessário para a etapa de classificação. A seguir, dois exemplos de técnicas de seleção de características são brevemente detalhadas.

Análise de Componentes Principais

Uma das técnicas mais empregadas nesta etapa é a análise de Componentes Principais (PCA, do inglês *Principal Component Analysis*). A PCA é uma técnica que visa a reconstrução de um conjunto de observações em um espaço de dimensionalidade reduzida,

preservando o máximo de informação possível contida nos dados originais (KRAMER, 1991).

Essa reconstrução ocorre através de uma transformação ortogonal que projeta os dados em um novo espaço cujas dimensões são chamadas de componentes principais, e são ordenadas segundo o grau de variância. Desta maneira, a primeira componente é responsável pela maior variabilidade dos dados, seguida da segunda componente, e assim sucessivamente.

O uso do PCA na análise de sinais neurais objetiva reconstruir os dados de EEG a partir de um pequeno número de componentes principais, sendo a análise das mesmas capaz de diferenciar entre estados de ativação cerebral distintos (ANDERSON; DEVU-LAPALLI; STOLZ, 1995).

Esta técnica já demonstrou melhorias nos resultados de classificação para algumas ICM (BASHASHATI; WARD; BIRCH, 2005).

Algoritmos Genéticos

Algoritmos genéticos são um conjunto de técnicas baseadas na teoria da evolução, que aplicam métodos heurísticos para procurar as melhores soluções em um dado espaço de busca. Nestas técnicas, um determinado número de indivíduos representam possíveis soluções do problema que se deseja otimizar.

Cada um dos indivíduos considerados é avaliado com base em uma função de *fitness* pré-determinada e novos indivíduos são criados a partir daqueles que apresentam melhor desempenho. Esta técnica leva a uma população final de indivíduos que possui melhores soluções para o problema que se deseja solucionar.

No caso particular do P300, o uso de algoritmos genéticos permite identificar qual combinação de características é mais adequada para sua classificação, fornecendo um meio efetivo de selecioná-las (CITI *et al.*, 2008). Para tanto, os indivíduos são formados a partir de diferentes características e aqueles que apresentam melhor desempenho são selecionados.

3.3.4 Classificação de Características

A *classificação de características* é a etapa do processamento dos sinais que transforma as características de interesse em sinais de controle lógicos ou classes de comando, como *target* e *non-target*. A seguir, dois exemplos de técnicas de classificação de características são brevemente detalhadas.

Detector de Limiar

O detector de limiar é um dos classificadores mais simples que existem, sendo utilizado em vários métodos de detecção em ICM (JANSEN *et al.*, 2004). Este procedimento baseia-se na comparação do valor de uma determinada característica com um limiar padrão previamente determinado.

Normalmente, o limiar padrão é determinado em uma etapa de treinamento, na qual a média coerente dos sinais é usada como fonte do limite apropriado para cada usuário, considerando-se a característica de interesse (i.e. pico, área, potência de determinada faixa de frequências) (ALLISON; PINEDA, 2003; FARWELL; DONCHIN, 1988).

Análise Discriminante Linear

A análise discriminante linear (LDA, do inglês *linear discriminant analysis*) é um classificador que utiliza combinações lineares para realizar a classificação de novas amostras (DUDA; HART; STORK, 2012).

No caso em que o problema envolve apenas duas classes, a LDA assumirá que uma amostra pertence a uma determinada classe se o seguinte critério for satisfeito:

$$\mathbf{w} \cdot \mathbf{x} > c, \quad (3.4)$$

em que \mathbf{x} é a amostra de entrada, c é um limiar constante previamente estabelecido, \mathbf{w} é um vetor de pesos determinado com base na média das amostras conhecidas pertencentes a cada classe, tal que:

$$\mathbf{w} \propto (\sum -1(\mu_1 - \mu_0))^{-1} \quad (3.5)$$

Como as médias e as variâncias das classes não são conhecidas, elas são obtidas a partir de um conjunto de treinamento. A classificação de uma nova amostra utilizando-se LDA ocorrerá com base apenas na combinação linear das amostras observadas.

Por sua simplicidade, a LDA é amplamente utilizada em ICM baseadas no P300 (KRUSIENSKI *et al.*, 2008; ALLISON; PINEDA, 2003; FARWELL; DONCHIN, 1988).

3.3.5 Pós-processamento

A etapa de *pós-processamento* é responsável por aumentar a performance da ICM visando diminuir o número de falsos positivos. A seguir, são explicadas duas técnicas de pós-processamento aplicadas a soletradores baseados em P300.

Correção Baseada em Potenciais Relacionados a Erro

Esta técnica baseia-se na detecção de ErrP (*error-related potentials*), que são potenciais registrados no escalpo após uma seleção errônea (FERREZ; MILLAN, 2008).

Desta maneira, a informação gerada pela característica de interesse pode ser pós-processada com base na detecção de ErrP, possibilitando a correção automática de um erro quando este potencial é detectado, por exemplo, gerado pela seleção errônea de uma letra em um *speller*. Tais potenciais podem ser utilizados como uma segunda fonte de informação para a ICM.

A grande vantagem desta técnica é a possível diminuição da frustração dos usuários da ICM, já que erros de detecção poderiam ser automaticamente corrigidos.

Predição de Seleção

A predição de seleção baseia-se em antever qual será a próxima escolha do usuário, aumentando a taxa de comunicação obtida pela ICM (KÜBLER *et al.*, 1999), similarmente ao auxílio de digitação em celulares. A probabilidade de seleção da próxima escolha é calculada com base nas escolhas anteriores do usuário. Desta forma, é possível realizar sugestões que aumentam a performance da ICM.

3.4 ICM Baseadas em P300 e Aplicações

ICM baseadas em P300 utilizam diferentes tipos de estimulação para eliciá-lo, incluindo estímulos visuais, auditivos e táteis. Os auditivos usam variações na frequência dos tons (FURDEA *et al.*, 2009; W; DONCHIN, 2006). Por sua vez, os estímulos táteis são apresentados por meio de um cinto que gera vibrações com diferentes tipos de intensidade (BROUWER; ERP, 2010). Contudo, a grande maioria das ICM que utiliza o P300 como sinal base emprega protocolos de estimulação visual.

O protocolo mais amplamente utilizado para eliciar o P300 visualmente é o *oddball*. Neste protocolo, o usuário é orientado a focar a atenção somente quando os símbolos de interesse são apresentados, o que é normalmente realizado contando-se o número de vezes que tal símbolo aparece. O soletrador P300 (*P300 speller*) comumente usa o protocolo

oddball e consiste em uma matriz de caracteres alfanuméricos onde as linhas e colunas são intensificadas uma de cada vez, de forma aleatória (FARWELL; DONCHIN, 1988).

Ao focar a atenção na linha ou coluna intensificada que apresenta o símbolo de interesse, espera-se que o P300 seja eliciado, enquanto este potencial não será gerado caso apenas símbolos comuns sejam apresentados. Os símbolos que eliciam o P300 são conhecidos como *target*, enquanto símbolos que não eliciam são chamados *non-target*.

O soletrador P300 permite que os usuários enviem uma sequência de letras para o computador. Um exemplo pode ser visualizado na Figura 3.2.

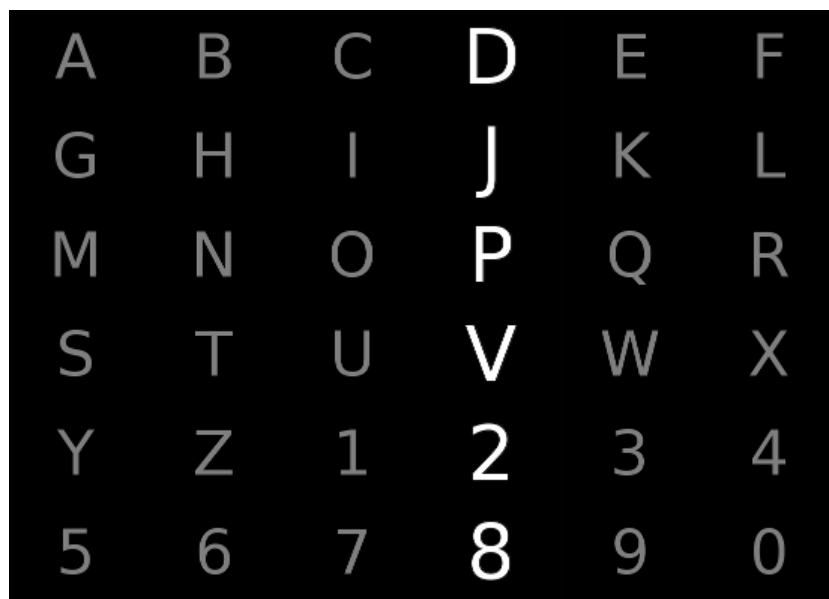


Figura 3.2 – Exemplo de soletrador P300.

Uma modificação do soletrador P300 permite que os usuários selecionem diálogos pré-definidos tais como "estou com fome", "apague a luz", o que permite atingir taxas de transferência de informação mais elevadas (W; DONCHIN, 2006).

Para testar a simplicidade de uso de ICM baseadas em P300, foi realizado um estudo sobre quantas pessoas eram capazes de soletrar uma palavra de cinco letras, com apenas 5 minutos de treino. Uma parcela de 72,8% dos voluntários conseguiram soletrar as palavras sem cometer erros (GUGER *et al.*, 2009). Este resultado se mostrou superior ao obtido em um estudo com ICM baseadas em imagética motora, onde apenas 6,2% dos voluntários conseguiram executar a tarefa proposta com sucesso, sem treinamento (GUGER *et al.*, 2003).

A necessidade mínima de treinamentos e os altos percentuais de classificação apresentados por ICM baseadas em P300 são uma grande vantagem. A facilidade de controle

por parte do usuário levou ao desenvolvimento de um número considerável outros trabalhos, além do soletrador P300, que empregam este tipo de potencial, abrangendo desde tecnologia assistiva até aplicações voltadas para o público em geral.

Um navegador de *internet* controlado por ICM foi desenvolvido e testado por voluntários saudáveis e com ALS. Utilizou-se uma matriz em que as células contém *links*, possibilitando a navegação (MUGLER *et al.*, 2010). Os usuários saudáveis e com ALS obtiveram, respectivamente, taxas de acerto de classificação de 90% e 73%, e taxas de transferência de informação de 14, 4bits/min e 8, 8bits/min, demonstrando o sucesso do *browser*. Além disso, os usuários com ALS reportaram grande satisfação no uso desta ICM (MUGLER *et al.*, 2010).

No *BrainPainting*, foi utilizada uma matriz 8x6 em que as células contém informações gráficas como cor e tamanho da linha (KÜBLER *et al.*, 2008; MÜNSSINGER *et al.*, 2010). Provou-se que as pinturas não eram apenas aleatórias, já que o usuário desta ICM conseguiu copiar pinturas de exemplo (KÜBLER *et al.*, 2008).

O *MindGame* é uma ICM baseada em P300 que surgiu com o intuito inicial de substituir os controles padrão de jogos eletrônicos, como teclado e *mouse*, por comandos cerebrais (FINKE; LENHARDT; RITTER, 2009). A detecção do P300 é traduzida em movimentos de um personagem em um mapa tridimensional. Esta ICM atingiu taxas de acerto de classificação de até 65%, usando apenas uma época do EEG (detecção *single-trial*). Durante sua operação, o usuário recebe avaliações de sua performance como um mecanismo de *neurofeedback* com vistas à melhoria de desempenho.

Estudos para o controle de casas virtuais, que incluem equipamentos como televisão, rádio, lâmpadas e outros itens, foram desenvolvidos e apontam para um futuro promissor das aplicações domóticas voltadas para pacientes com distúrbios neurológicos (BAYLISS; BALLARD, 1999; BAYLISS, 2003; ALOISE *et al.*, 2011) .

Outra aplicação de grande importância são as ICM que permitem o controle de cadeiras de rodas motorizadas a partir da detecção do P300 (REBSAMEN *et al.*, 2007). Nesta ICM, os símbolos de interesse apresentados são os destinos para os quais o usuário deseja se locomover, como o banheiro ou a cozinha. Ao focar a atenção nestes símbolos, o P300 é eliciado, permitindo mover a cadeira de rodas até o destino escolhido (ITURRATE *et al.*, 2009).

O grande desafio destas ICM é garantir a confiabilidade, já que a locomoção em ambientes não controlados é agravada pelo trânsito de pessoas e outros fatores. Contudo, representam um importante ganho de autonomia para os pacientes. Neste contexto,

desenvolveu-se uma ICM que permite controlar alguns aplicativos a partir de um soletrador P300 embutido no computador. Entretanto, a avaliação desta ICM mostrou que ainda existem grandes avanços a serem realizados para possibilitar o uso na vida diária (ZICKLER *et al.*, 2011).

Independentemente da aplicação, aumentar a taxa de acertos de classificação e a velocidade de comunicação é o principal desafio enfrentado no desenvolvimento de ICM baseadas em P300. Uma das formas de se realizar isso é diminuir o número de épocas de EEG necessárias para se obter um valor de SNR razoável para o PRE. Contudo, técnicas *single-trial*, que utilizam apenas uma época, ainda apresentam baixas taxas de acerto de classificação.

4 Metodologia

Este capítulo apresenta a metodologia empregada na realização do projeto. São apresentados o protocolo experimental e as técnicas de processamento de sinais utilizadas. A condução dos testes e os procedimentos de análise dos resultados são brevemente descritos.

4.1 Participantes e Aquisição dos Sinais Eletroencefalográficos

Para a realização dos testes da ICM foi utilizada a base de dados *Open P300 Speller Database*¹, disponibilizada na internet por Ledesma-Ramirez *et al.* (2010).

O EEG foi coletado usando o *gUSBamp (gTek R)*, um amplificador de sinais biológicos de 16 canais. Utilizou-se como referência o lóbulo auricular direito e o terra foi conectado ao mastoide direito. Os sinais foram filtrados entre 0,1 e 60Hz, e adquiridos a uma taxa de 256Hz. Foram registradas dez derivações de EEG: Fz, Cz, C3, C4, Pz, P3, P4, Oz, PO7, PO8. A localização das derivações pode ser visualizada na Figura 4.1:




Figura 4.1 – Localização das derivações utilizadas. (Adaptada de (NIEDERMEYER; SILVA, 2004))

¹ A base de dados pode ser encontrada em: <http://akimpech.izt.uam.mx/p300db/doku.php>

Os sinais foram adquiridos de vinte e quatro voluntários saudáveis, dezesseis homens e oito mulheres, com idade entre 19 e 25 anos, sem histórico de problemas visuais ou com correção. Os dados de cada voluntário, cujo nome foi substituído por um identificador, podem ser conferidos na [Tabela 4.1](#).

Tabela 4.1 – Voluntários submetidos ao protocolo experimental.

Identificador	Idade	Sexo
ACS	23	Feminino
APM	23	Masculino
ASG	23	Feminino
ASR	23	Masculino
CLL	25	Feminino
DCM	22	Masculino
DLP	23	Feminino
DMA	25	Masculino
ELC	21	Feminino
FSZ	21	Feminino
GCE	22	Masculino
ICE	22	Masculino
IZH	22	Feminino
JLD	22	Masculino
JLP	21	Masculino
JMR	23	Masculino
JSC	24	Masculino
JST	23	Masculino
LAG	23	Feminino
LAC	23	Feminino
LGP	22	Masculino
PGA	22	Masculino
WFG	21	Masculino
XCL	23	Masculino

Fonte: ([LEDESMA-RAMIREZ et al., 2010](#))

4.2 Protocolo Experimental

O protocolo experimental adotado utiliza uma matriz de símbolos agrupados em linhas e colunas, razão pela qual é comumente conhecido como paradigma linha-coluna (RCP, do inglês *row-column paradigm*).

Durante a execução do protocolo, os voluntários foram instruídos a fixar o olhar nos símbolos indicados na tela do estimulador. Tais símbolos foram são retirados a partir de uma palavra pré-definida, soletrando-se um símbolo de cada vez. Inicialmente, cada símbolo apresenta a mesma cor durante um período chamado de período entre tentativas – *inter-trial interval* (*ITI*).

Após o *ITI*, as linhas e colunas da matriz são intensificadas – através do realce da cor – por um período conhecido como intervalo de intensificação (*IIE*). Terminado o intervalo de intensificação, todos os símbolos da matriz permanecem com a mesma cor, no período conhecido como intervalo de não-intensificação (*INI*), até que um novo *IIE* ocorra. A soma do *IIE* e do *INI* é conhecida como intervalo entre estímulos – *inter-stimulus interval* (*ISI*). No protocolo experimental adotado, utilizou-se um valor de 2,5 s para o *ITI*, 0,0625 s para o *IIE* e 0,0625 s para o *INI*.

Uma rodada completa de estimulação é composta pela intensificação de todas as linhas e colunas, num total de doze intensificações (doze estímulos). A linha ou coluna a ser intensificada é definida aleatoriamente, de modo a eliciar o P300 (FARWELL; DONCHIN, 1988).

O usuário é instruído a contar mentalmente o número de vezes que as linhas e colunas que contém o símbolo a ser selecionado são intensificadas, de modo a garantir a atenção aos estímulos apresentados. Quando isso ocorre, a eliciação do P300 gerará um evento do tipo *target*. A intensificação de todas as outras linhas ou colunas, que não contém o símbolo a ser selecionado, é conhecida como um evento do tipo *non-target*. Foi solicitado que os participantes evitassem piscar ou mover os olhos, a fim de evitar artefatos resultantes do eletrooculograma (EOG).

Em cada rodada de estimulação, existem 2 eventos do tipo *target* (linha e coluna que contém o símbolo a ser selecionado) e 10 eventos do tipo *non-target* (todas as outras linhas e colunas). Espera-se que os eventos *target* eliciem o P300 (PIRES; NUNES; CASTELO-BRANCO, 2011). Assim, identificando-se a ocorrência do P300, é possível identificar a linha e coluna que contém o símbolo de interesse.

4.3 Processamento dos Sinais

4.3.1 Pré-processamento

Para cada linha e coluna intensificadas foram extraídas épocas de 600 ms, cujo início é o instante de ocorrência do estímulo. Cada rodada intensifica todas as linhas e colunas uma única vez, em ordem aleatória. As linhas e colunas foram apresentadas durante 15 rodadas de estimulação, gerando 15 épocas de EEG.

As épocas foram filtradas com passa-faixas com frequências de corte de 0,1 a 60Hz. Após esta etapa, eles foram re-referenciados utilizando-se a técnica CAR, devido aos bons resultados apresentados na detecção do P300 (ALHADDAD *et al.*, 2012).

Para aumentar a SNR do P300, efetuou-se o cálculo da média coerente das épocas de EEG de cada uma das janelas correspondentes às linhas e colunas. Para verificar a variação do desempenho da ICM de acordo com o número de épocas, os algoritmos das etapas posteriores foram testados nas médias coerentes com número de épocas $N_{ep} = 1, 2, 3...15$.

4.3.2 Extração e Seleção de Características

Após o cálculo das médias coerentes para cada número de épocas, foram extraídos dois grupos de características. No primeiro, as características procuram identificar parâmetros capazes de modelar o comportamento do P300, enquanto o segundo procura identificar padrões espaço-temporais nas leituras de cada derivação que reflitam a ocorrência deste potencial. Após a seleção das características, estas foram normalizadas entre -1 e 1 , para cada voluntário.

Características Baseadas em Parâmetros P300

O primeiro grupo de características extraídas dos sinais buscou refletir parâmetros proeminentes do P300, abordagem esta utilizada em outros trabalhos (FARWELL; DONCHIN, 1988; ALLISON; PINEDA, 2003). Assim, a partir das médias coerentes dos sinais, foram calculadas diversas características do EEG no intervalo até 600ms pós-estímulo, listadas na Tabela 4.2 e ilustradas na Figura 4.2.

Para identificar quais destas características acarretam melhor desempenho na detecção do P300, empregou-se testes estatísticos visando identificar se há significância estatística em cada um dos coeficientes de um modelo de regressão logística. A variável de resposta de tal modelo é o tipo do sinal que está sendo avaliado, podendo assumir dois valores: *target* ou *non-target*. Para descrever o comportamento de variáveis como esta,

Tabela 4.2 – Resumo das características baseadas em parâmetros P300.

Característica	Descrição
$PPeak$	Amplitude do maior pico pós-estímulo
$PLat$	Latência do maior pico pós-estímulo. Este valor foi normalizado em 6 faixas, de 0 a 100 ms, 100 a 200 ms, até 500 a 600 ms
$NPeak$	Amplitude do maior vale pós-estímulo
$NLat$	Latência do maior vale pós-estímulo. Este valor foi normalizado em 6 faixas, de 0 a 100 ms, 100 a 200 ms, até 500 a 600 ms
$Area$	Valor da área entre o maior vale e o maior pico pós-estímulo
RMS	Valor RMS entre o maior vale e o maior pico pós-estímulo




Figura 4.2 – Ilustração das características baseadas em parâmetros P300.

utiliza-se a seguinte equação (MYERS *et al.*, 2012):

$$E(y_i) = \frac{e^{(\beta_0 + x_i \beta_1)}}{(1 + e^{(\beta_0 + x_i \beta_1)})} = \frac{1}{(1 + e^{-(\beta_0 + x_i \beta_1)})}, \quad (4.1)$$

onde $E(y_i)$ é o valor esperado da variável de resposta y_i , x_i é a variável explanatória (característica), β é um coeficiente associado a uma dada característica. Permitindo o uso de múltiplas características, a Equação 4.1 torna-se:

$$E(y_i) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik})}} \quad (4.2)$$

A Equação 4.2 modela a relação entre y_i e as características x_i , a partir dos coeficientes β_i , que são identificados a partir de um estimador de verossimilhança. O valor esperado $E(y_i)$ pode ser usado como um valor de probabilidade de modo a prever o valor da variável de resposta (MYERS *et al.*, 2012).

Pretende-se seleccionar quais características são mais relevantes para a detecção do P300, dentre aquelas listadas na Tabela 4.2. Para tanto, propõe-se utilizar testes de significância em cada um dos coeficientes β_k do modelo de regressão logística (VIANA; BATISTA; MELGES, 2014). Desta maneira, pode-se formular a seguinte hipótese:

$$\begin{aligned} H_0 : \beta_k &= 0 \\ H_1 : \beta_k &\neq 0 \end{aligned} \quad (4.3)$$

Para testar a hipótese da Equação 4.3 utiliza-se uma estatística chamada de estatística Wald, que tende assintoticamente para uma distribuição normal (MYERS *et al.*, 2012):

$$Z_0 = \frac{\hat{\beta}_k}{sd(\hat{\beta}_k)} \quad (4.4)$$

Observa-se que, à medida que o desvio padrão cresce, Z_0 tenderá a zero. Assim, um coeficiente necessita possuir um baixo desvio padrão (em comparação com seu valor estimado) para ser estatisticamente significativo.

A realização de testes em Z_0 pode ser usada para verificar a significância estatística de cada característica, fornecendo informações de como cada uma delas contribui para a capacidade do modelo de distinguir entre as classes *target* e *non-target* (VIANA; BATISTA; MELGES, 2014).

Esta abordagem foi utilizada para avaliar quais características baseadas em parâmetros P300 melhoram significativamente as taxas de detecção, avaliadas na derivação Cz. As características seleccionadas (amplitude do maior pico, valor RMS e latências de ocorrência do maior pico e do maior vale) foram passadas à etapa de classificação (subseção 4.3.3), para implementação de uma ICM com detecção baseada em parâmetros do P300.

Características Baseadas em Padrões Espaço-Temporais das Formas de Onda

O segundo grupo de características baseou-se na busca de padrões espaço-temporais nas formas de onda correspondentes a cada estímulo como forma de identificar a ocorrência do P300.

Como os sinais de cada janela de EEG possuem uma extensão de $600ms$, existem 154 pontos adquiridos a $256 Hz$. Cada um destes pontos pode ser tratado como uma característica do sinal, já que seu valor fornece informações espaço-temporais da ocorrência do P300, em virtude de sua latência e da derivação onde foi registrado.

Entretanto, como foram utilizadas 10 derivações, há um total de 1540 características. Para reduzir esta dimensionalidade, utilizou-se o algoritmo de seleção de características conhecido como LARS (do inglês *Least Angle Regression*), proposto por [Efron et al. \(2004\)](#).

Admitindo-se que a variável de resposta pode ser determinada por uma combinação linear de um subconjunto de variáveis explanatórias (características), o LARS estima quais variáveis incluir no modelo da [Equação 4.5](#), ordenando-as segundo seu grau de contribuição para determinação da variável de resposta:

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_jx_j, \quad (4.5)$$

onde \hat{y} é a estimativa da variável de resposta, x_j são as características e b_j são os coeficientes do modelo.

Em sua execução, o LARS utiliza o seguinte procedimento ([EFRON et al., 2004](#)), que está esquematizado na [Figura 4.3](#) :

1. Zera todos os coeficientes b_j do modelo;
2. Encontra a característica x_j que possui maior correlação com a variável de resposta;
3. Aumenta o coeficiente da característica x_j na direção do sinal de correlação com a variável de resposta. Calcula o resíduo $r = y - \hat{y}$ e pára quando outra característica x_k apresenta correlação maior ou igual com r ;
4. Aumenta os coeficientes das características x_j e x_k na direção conjunta dos seus mínimos quadrados até que outra característica apresente o mesmo grau de correlação com os resíduos;

5. Continua até que o número especificado de características seja incluído no modelo.




Figura 4.3 – Esquema do LARS. Adaptada de en.wikipedia.org.

Utilizando o LARS, reduziu-se o número de características de 1540 para 100, compondo um vetor de características com os valores de amplitude em diferentes instantes pós-estímulo, em diferentes derivações de EEG.

Este vetor de características foi passado como entrada à etapa de classificação, para implementação de uma ICM com detecção baseada em padrões espaço-temporais das formas de onda.

4.3.3 Classificação a Partir dos Valores da Função de Regressão do *Support Vector Regression*

O SVM (do inglês *support vector machine*) é um classificador de margem máxima, que encontra o conjunto ótimo de hiperplanos que pode ser usado para a classificação de uma amostra de dados. A melhor separação ocorrerá quando a distância entre o conjunto de hiperplanos e o ponto mais próximo for maximizada (BOSER; GUYON; VAPNIK, 1992; CORTES; VAPNIK, 1995).

Para a classificação binária, uma amostra pode ser classificada como pertencendo a uma de duas classes – um lado ou outro de um hiperplano, por exemplo. Neste caso, tem-se que:

$$(x_{11}, x_{12}, \dots, x_{1m}), \dots (x_{n1}, x_{n2}, \dots, x_{nm}) \in R^N \times (-1, 1), \quad (4.6)$$

onde x_{nm} é a m -ésima amostra da n -ésima variável de entrada; N é o número de dimensões dos dados; $(-1, 1)$ são os rótulos de duas classes arbitrárias.

O hiperplano que separa os dados pode ser descrito por um vetor de pesos w e por um termo de *bias* b . Assim, o rótulo da classe de um novo dado pode ser predito a partir da equação 4.7:

$$f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b \quad (4.7)$$

Na Equação 4.7, o vetor de dados x foi projetado no vetor de pesos w . Se w for perpendicular ao hiperplano que separa as duas classes, então o sinal da projeção revelará qual é a classe da amostra de entrada.

Para o cálculo de w , são usados os vetores de margem, ou seja, as amostras que encontram-se na fronteira entre as classes. Estes vetores são chamados de *support vectors*, razão do nome SVM (BURGES, 1998). Um esquema do SVM pode ser visualizado na Figura 4.4.




Figura 4.4 – Esquema do classificador SVM. Adaptada de en.wikipedia.org.

Deseja-se que w e b sejam escolhidos de forma que a distância entre os hiperplanos paralelos que separam os dados seja máxima. Estes dois hiperplanos podem ser descritos pelas equações abaixo:

$$\mathbf{w} \cdot \mathbf{x} - b = 1 \quad (4.8)$$

$$\mathbf{w} \cdot \mathbf{x} - b = -1 \quad (4.9)$$

A distância entre os dois hiperplanos é dada por $\frac{2}{\|\mathbf{w}\|}$. Desta forma, para que ela seja maximizada, é necessário que $\|\mathbf{w}\|$ seja minimizada, ao mesmo tempo que é necessário evitar que os pontos x caiam na margem de separação. A solução para esse problema é dada por:

$$w = \sum_{i=1}^n \alpha_i c_i x_i, \quad (4.10)$$

onde α é um multiplicador de *Lagrange* associado às restrições do problema; c_i é o rótulo da classe $(-1, 1)$; e x_i é uma característica do vetor de entrada.

A fim de permitir uma restrição menos rígida para a margem de classificação para os casos em que os dados não são perfeitamente separáveis, utiliza-se a seguinte equação (CORTES; VAPNIK, 1995):

$$w = \sum_{i=1}^{N_s} \alpha_i c_i x_i, \quad (4.11)$$

onde N_s é o número de vetores de suporte utilizado.

Desta forma, substituindo-se a Equação 4.11 na Equação 4.7, obtém-se:

$$f(\mathbf{x}) = \sum_{i=1}^{N_s} \alpha_i c_i (x_i \cdot \mathbf{x}) + b \quad (4.12)$$

Normalmente, o produto interno $(x_i \cdot \mathbf{x})$ é substituído por uma função de *kernel* simétrica $\phi(\mathbf{x}, x_i)$, o que transforma o espaço dos dados em um espaço de características com dimensão normalmente maior. Esta técnica fornece maior flexibilidade na separação dos dados (BURGES, 1998). A seguinte função de *kernel* é normalmente utilizada (KAPER *et al.*, 2004):

$$\phi(\mathbf{x}, x_i) = e^{-\frac{\|\mathbf{x} - x_i\|^2}{2\sigma^2}}, \quad (4.13)$$

onde σ é um parâmetro escolhido.

Portanto, substituindo-se a [Equação 4.13](#) na [Equação 4.12](#), obtém-se a equação de classificação do SVM:

$$f(\mathbf{x}) = \sum_{i=1}^{N_s} \alpha_i c_i \phi(\mathbf{x}, x_i) + b \quad (4.14)$$

A regressão usando SVM, chamada SVR (do inglês *support vector regression*) é similar ao caso da classificação. Contudo, ao invés de separar os dados em duas classes distintas, a intenção é encontrar uma função de regressão que forneça o menor erro possível, ao mesmo tempo em que é definida uma margem de tolerância na qual as amostras fora da curva de regressão não geram penalização (SCHÖLKOPF *et al.*, 2000).

Para tanto, a função de custo utilizada pelo SVR é definida por:

$$|y - f(\mathbf{x})|_\epsilon = \max\{0, |y - f(\mathbf{x}) - \epsilon|\}, \quad (4.15)$$

em que o parâmetro ϵ , escolhido *a priori*, define o tamanho da margem de tolerância na curva de regressão.

Desta maneira, o SVR busca encontrar funções do seguinte tipo:

$$f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b, \quad (4.16)$$

Da mesma forma que no SVM, para que seja possível realizar uma regressão não-linear dos dados (o que fornece maior flexibilidade na regressão), utilizam-se funções de *kernel*, similares àsquelas da [Equação 4.13](#). O uso destas funções projeta as amostras de entrada em um espaço de características de dimensionalidade normalmente maior, através de transformações não-lineares. A [Figura 4.5](#) ilustra a regressão baseada em SVR.

Verifica-se que, quando as amostras encontram-se a uma distância da curva de regressão menores que ϵ (faixa demarcada pelas linhas pontilhadas), a função de custo não penaliza a função de regressão encontrada.

Entretanto, quando as amostras estão fora da faixa assinalada, as distâncias são computadas e penalizam os parâmetros encontrados para a curva de regressão. Devido




Figura 4.5 – Esquema de regressão baseada em SVR. Adaptada de (SCHÖLKOPF *et al.*, 2000).

a este fato, as amostras fora da faixa são consideradas os vetores de suporte no caso da regressão, pois são elas que determinam os pesos da função de regressão.

Em suma, o SVR realiza uma regressão linear no espaço de características projetado a partir da função de *kernel*, utilizando a função de custo definida pela Equação 4.15. Ao mesmo tempo, tenta-se reduzir a complexidade do modelo, que é dada por $\|w^2\|$. Esta situação pode ser definida pelo seguinte problema de otimização:

$$\min \tau(w, \xi^*, \epsilon) = \frac{\|w\|^2}{2} + C \left(\sum_{i=1}^n (\xi_i + \xi_i^*) \right) \quad (4.17)$$

s.a :

$$y_i - f(x_i, w) \leq \epsilon + \xi_i^* \quad (4.18)$$

$$f(x_i, w) - y_i \leq \epsilon + \xi_i \quad (4.19)$$

$$\xi_i, \xi_i^* \geq 0, i = 1 \dots n, \quad (4.20)$$

em que ξ_i e ξ_i^* são as distâncias das amostras até a faixa de não-penalização do SVR.

A solução do problema ocorre com a introdução dos multiplicadores de Lagrange α e α^* , e é dada pelas equações abaixo:

$$f(\mathbf{x}) = \left(\sum_{i=1}^{N_{sv}} (\alpha_i - \alpha_i^*) \phi(\mathbf{x}, x_i) \right) \quad (4.21)$$

s.a :

$$0 \leq \alpha_i^* \leq C \quad (4.22)$$

$$0 \leq \alpha_i \leq C, \quad (4.23)$$

em que N_{sv} é o número de vetores de suporte utilizados; α e α^* são os multiplicadores de Lagrange associados e C é um parâmetro que controla o compromisso entre a minimização do erro de regressão e a complexidade do modelo.

Os valores obtidos a partir do cálculo de $f(\mathbf{x})$ estão associados ao conjunto de características \mathbf{x} . Desta forma, as características extraídas de cada janela de sinais, conforme a [subseção 4.3.2](#), serão utilizadas para calcular o valor de regressão associado.

Desta forma, os sinais que possuírem o maior valor de regressão dentre as linhas e colunas (conforme protocolo experimental descrito na [seção 4.2](#)) serão considerados como sinais do tipo *target*, enquanto todos os outros sinais serão considerados sinais do tipo *non-target*.

Esta metodologia possibilitará determinar qual o símbolo selecionado pelo usuário, a partir da identificação dos estímulos correspondentes à linha e à coluna que eliciaram o P300 (sinais *target*), obtidos a partir do maior valor de regressão encontrado para os sinais. Um diagrama simplificado do processamento dos sinais pode ser visualizado na [Figura 4.6](#).

4.4 Avaliação de Desempenho da ICM

O desempenho da ICM será baseado a partir de duas métricas: taxa de acertos e taxa de transferência de informação.

4.4.1 Taxa de Acertos

A taxa de acertos de símbolos A_s é definida como:

$$A_s = \frac{N_{cs}}{N_{ts}}, \quad (4.24)$$

em que N_{cs} é o número de símbolos corretamente identificados e N_{ts} é o número total de símbolos apresentados.

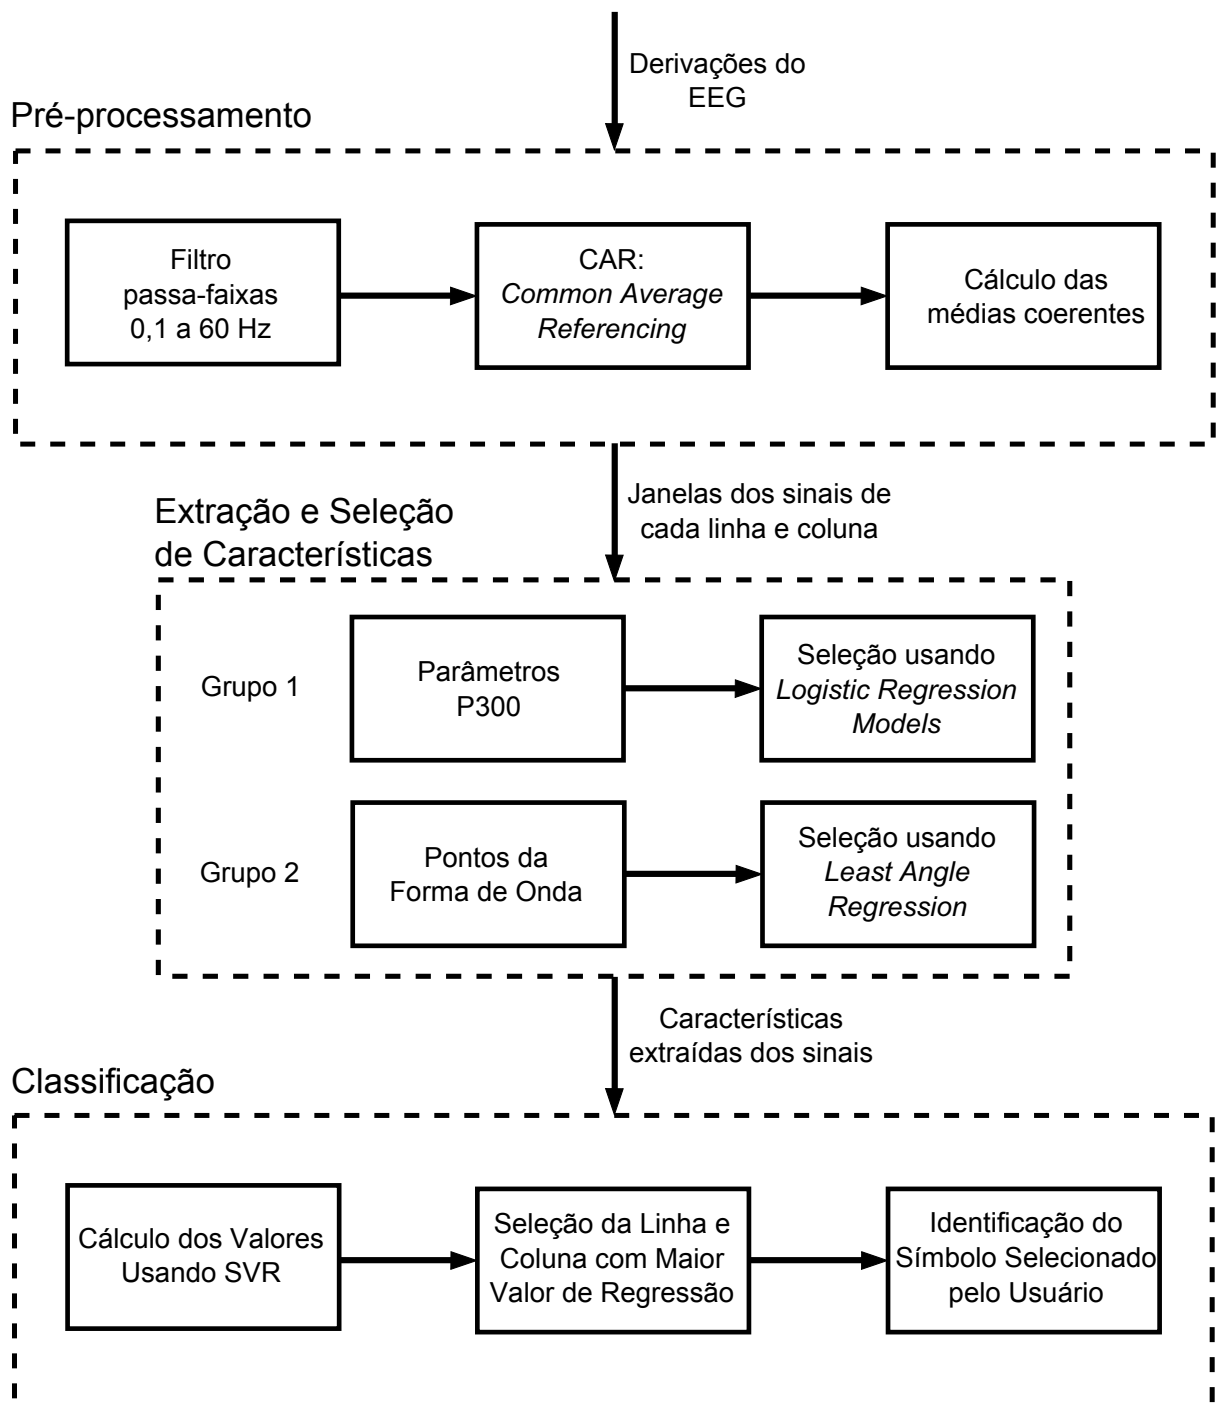


Figura 4.6 – Diagrama do processamento dos sinais.

4.4.2 Taxa de Transferência de Informação

A taxa de transferência de informação T_B de uma ICM é normalmente medida em *bits/min*, sendo comumente utilizada para comparações de performance entre diferentes ICM (SERBY; YOM-TOV; INBAR, 2005).

Para se calcular o número de *bits* B que podem ser transmitidos em cada tentativa,

utiliza-se a equação abaixo (PIERCE, 1980):

$$B = \log_2 N + P \log_2 P + (1 - P) \log_2 \left(\frac{1 - P}{N - 1} \right), \quad (4.25)$$

onde N é o número de símbolos apresentados e P é a probabilidade que o símbolo de interesse seja classificado corretamente, o que corresponde à taxa de acertos A_s .

Para se obter a taxa de transferência de informação, divide-se B pelo tempo necessário para que um símbolo seja corretamente identificado em minutos, isto é, o tempo de seleção do símbolo.

O tempo de seleção do símbolo t_{sel} é função do tempo de cada rodada e do número de tentativas de seleção (número de épocas utilizadas), sendo definido abaixo, em segundos:

$$t_{sel} = ITI + 12 (II + INI) N_{ep} = 2,5 + 12 (0,0625 + 0,0625) N_{ep} = 4 N_{ep}, \quad (4.26)$$

em que N_{ep} é o número de épocas utilizadas para seleção do símbolo.

Unindo-se a Equação 4.27 e a Equação 4.25 e convertendo-se o resultado para *bits/min*, obtém-se a taxa de comunicação da ICM, T_B :

$$T_B = 15 \frac{\log_2(N) + A_s \log_2(A_s) + (1 - A_s) \log_2 \left(\frac{1 - A_s}{N - 1} \right)}{N_{ep}}, \quad (4.27)$$

4.4.3 Análise Estatística

As métricas obtidas para os dois tipos de ICM desenvolvidos foram comparadas estatisticamente por meio do Teste de Wilcoxon Pareado (Signed-rank) com $\alpha=0,01$.

5 Resultados

Este capítulo apresenta os resultados da análise dos potenciais P300 e do desempenho da ICM implementada.

5.1 Formas de Onda dos Potenciais P300

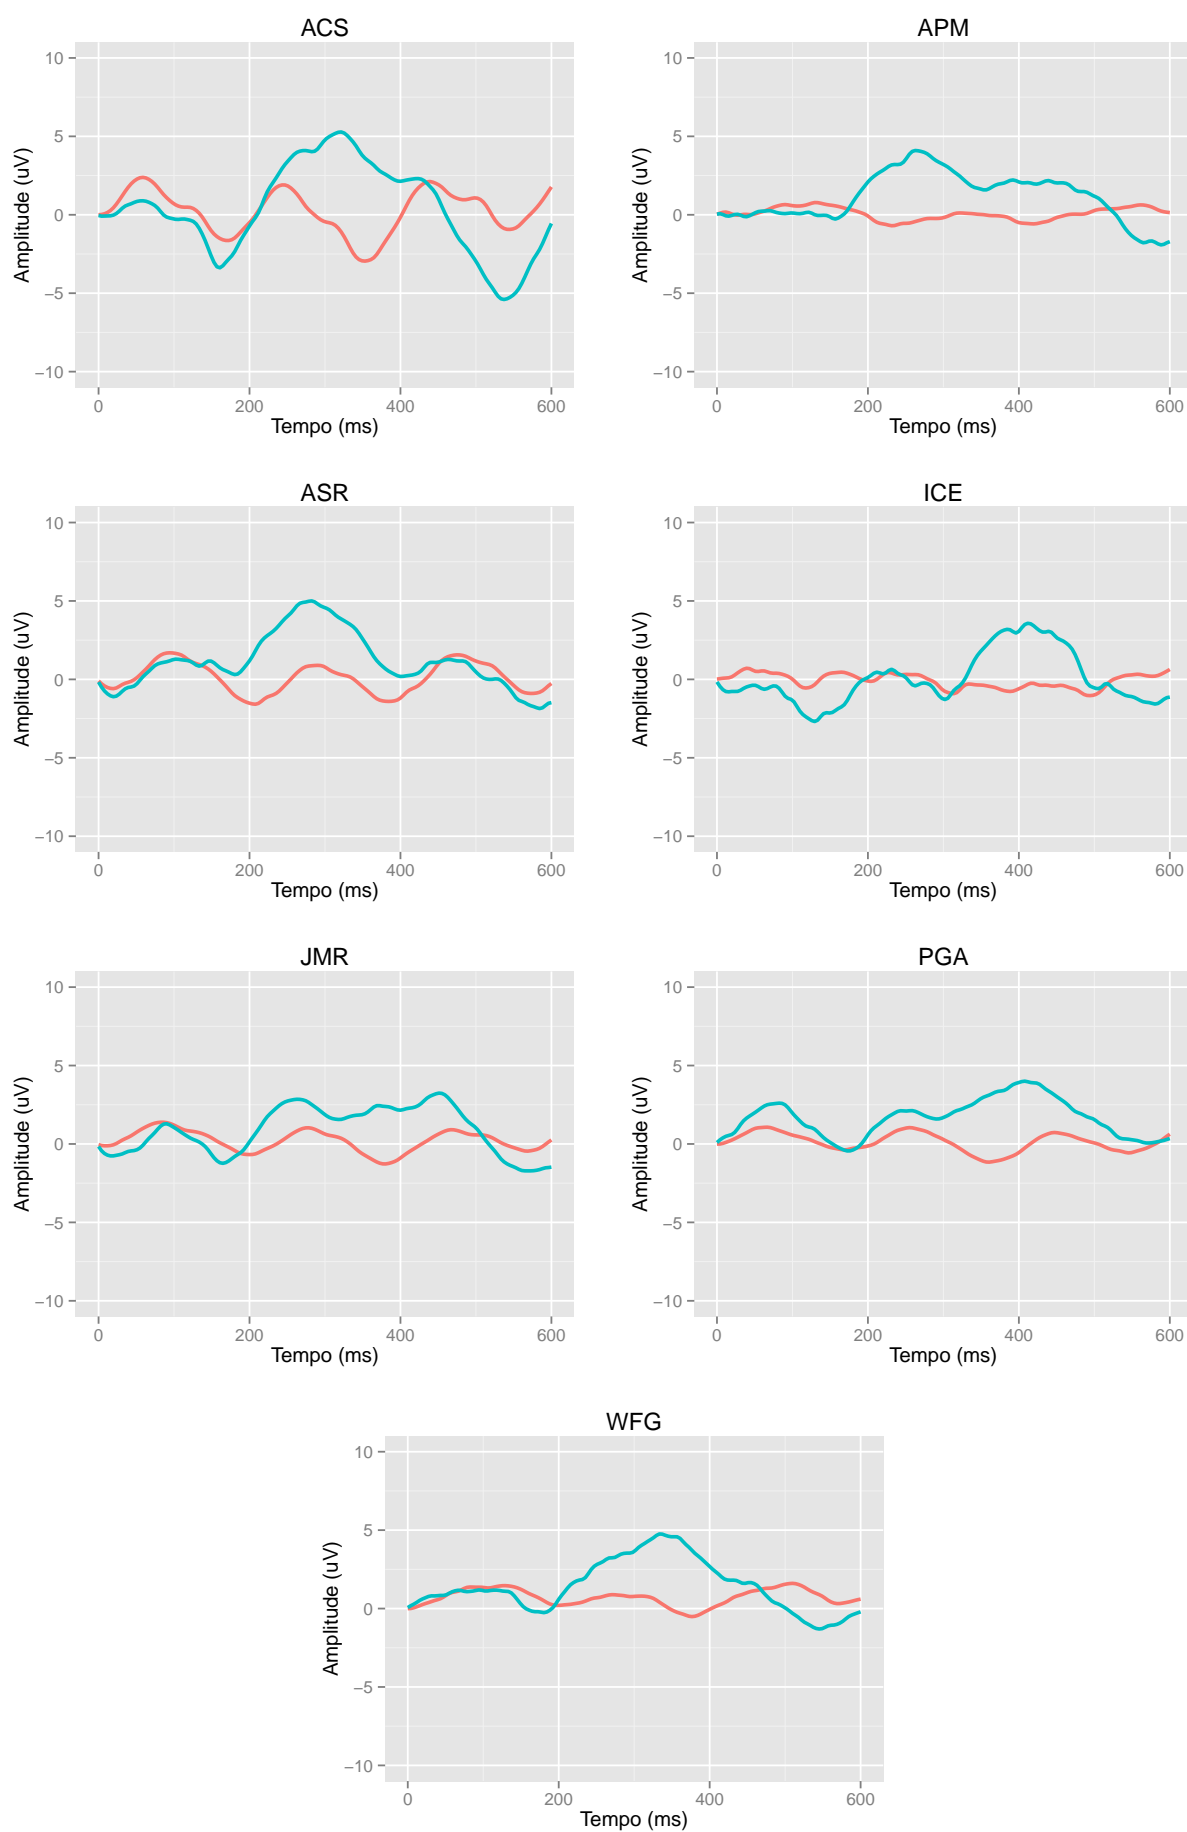
Visando ilustrar a elevada variabilidade inter-indivíduo do potencial P300, as formas de onda foram obtidas calculando-se o de 240 épocas para a derivação Cz. Utilizou-se épocas de EEG de 16 símbolos diferentes, já que não é esperada variação na morfologia do sinal devido ao tipo de símbolo. Tais traçados foram reunidos em quatro categorias, considerando sua similaridade morfológica.

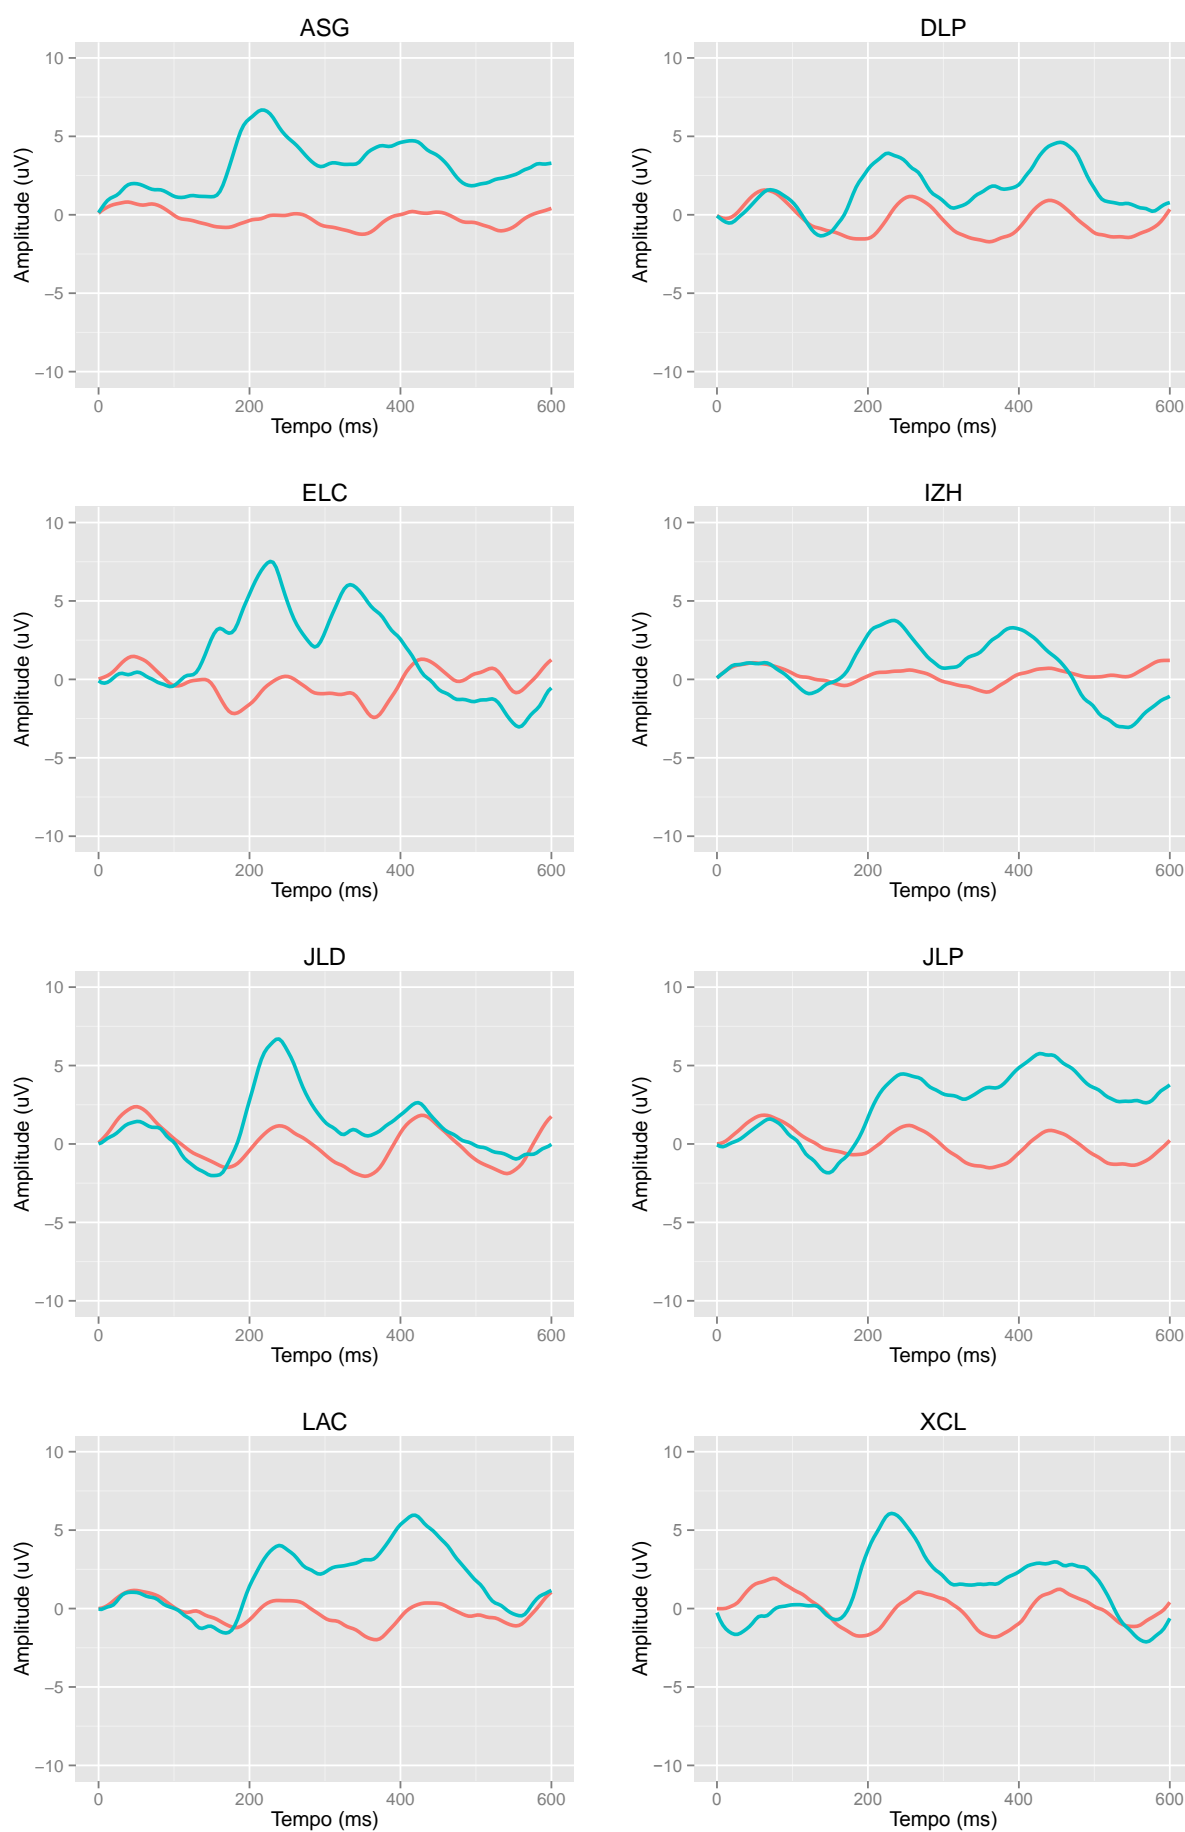
A [Figura 5.1](#) mostra os sinais *target* (azul) e *non-target* (vermelho) para o primeiro grupo, composto pelos voluntários ACS, APM, ARS, ICE, JMR, PGA e WFG. Este grupo apresenta formas de onda que se aproximam do potencial P300 padrão, mostrando um pico entre 200 e 400ms.

No segundo grupo ([Figura 5.2](#)), composto pelos voluntários ASG, DLP, ELC, IZH, JLD, JLP, LAC e XCL, observa-se que os sinais *target* apresentam um P300 bífido, com dois picos ao invés de um. Entretanto, existe uma diferença evidente de amplitude entre estes picos e o sinal *non-target*.

As formas de onda para o terceiro grupo ([Figura 5.3](#)), composto pelos voluntários DCM, DMA, FSZ, JSC e JST, caracterizam-se por apresentarem diferença de amplitude muito tênue entre os sinais *target* e *non-target*.

O quarto grupo ([Figura 5.4](#)), onde se incluem os voluntários CLL, GCE, LAG e LGP, apresenta formas de onda que não se assemelham ao P300 padrão e nem a uma média tendendo a zero, como os sinais *non-target*.

Figura 5.1 – Sinais *target* (azul) e *non-target* (vermelho) do primeiro grupo.

Figura 5.2 – Sinais *target* (azul) e *non-target* (vermelho) do segundo grupo.

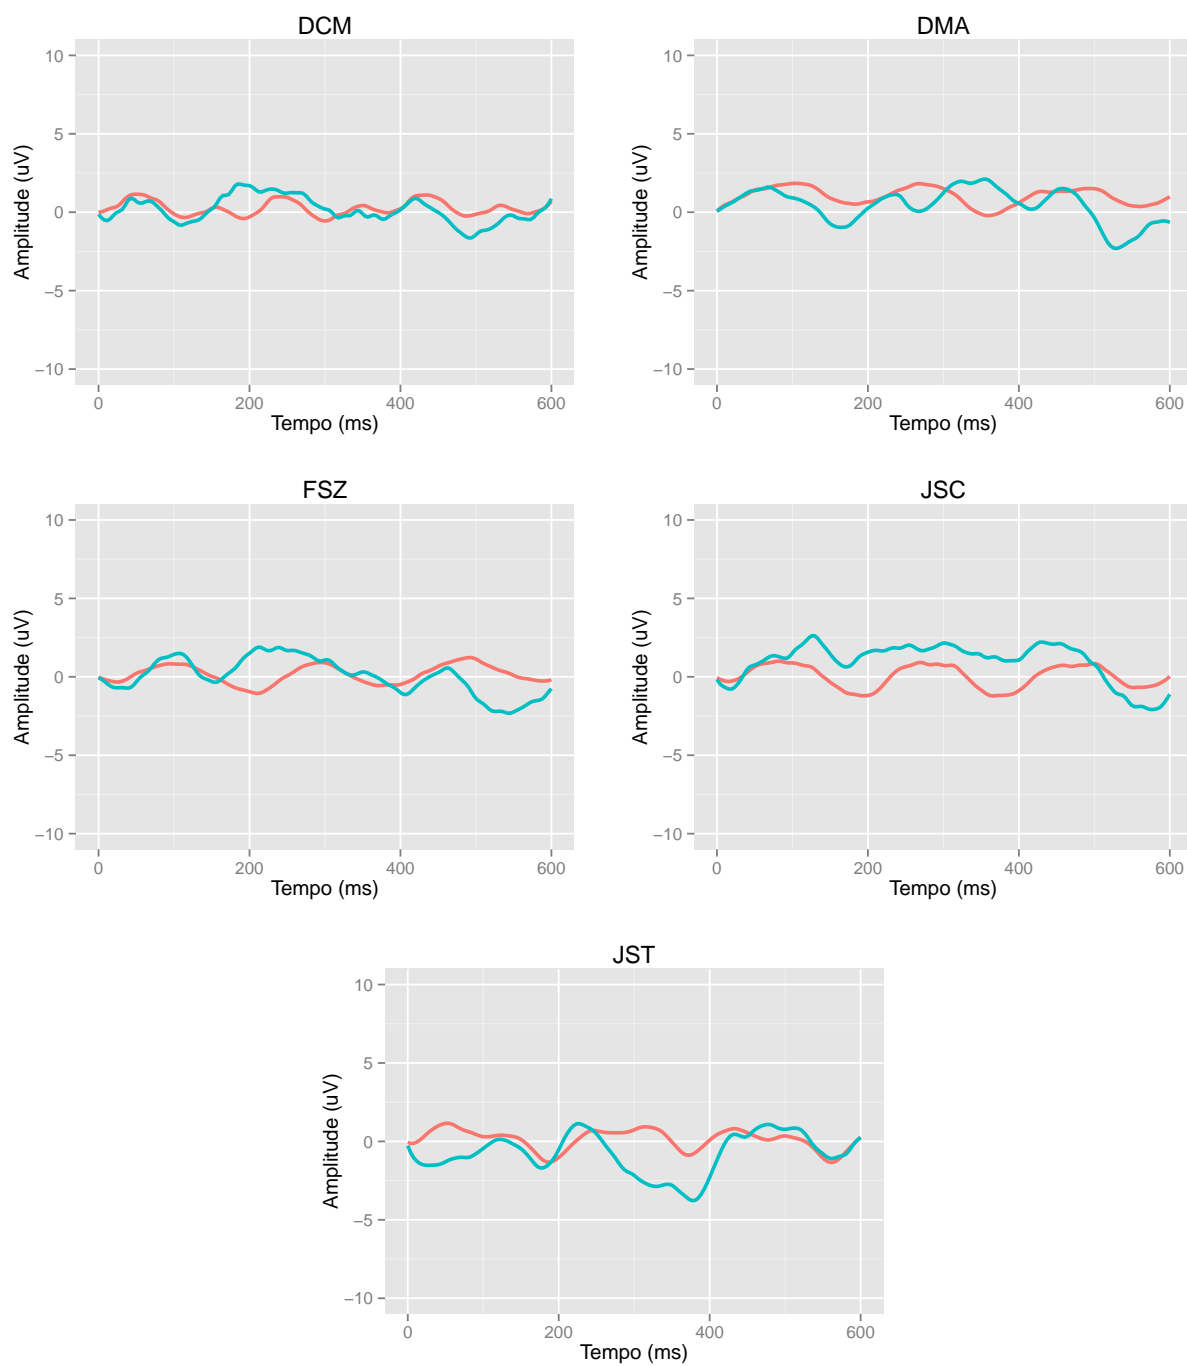


Figura 5.3 – Sinais *target* (azul) e *non-target* (vermelho) do terceiro grupo.

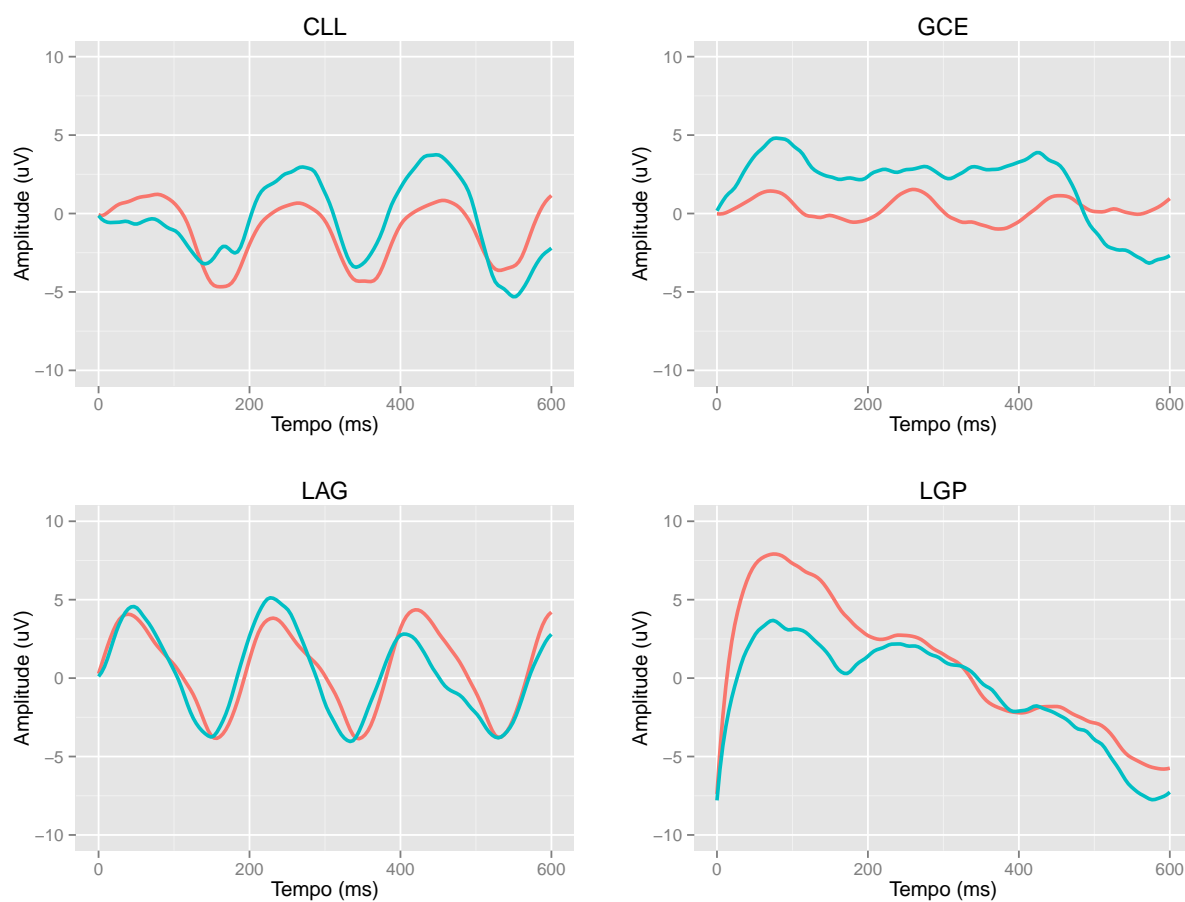


Figura 5.4 – Sinais *target* (azul) e *non-target* (vermelho) do quatro grupo.

5.2 Desempenho da ICM Baseada em Parâmetros P300

5.2.1 Parâmetros Extraídos dos Potenciais P300

O uso do teste estatístico sobre os coeficientes do modelo de regressão logística revelou que a amplitude do maior pico ($PPeak$) ($p < 0,007$) e o valor RMS ($p < 0,003$) são parâmetros significativos para detecção do P300, enquanto o valor da área ($Area$) e do maior vale ($NPeak$) não o são, considerando-se a influência isolada destes parâmetros. As interações entre os parâmetros considerados também foram avaliadas.

A [Figura 5.5](#) mostra a influência do valor do $PPeak$ na probabilidade de detecção do P300. As linhas sólidas representam as probabilidades de detecção à medida que a amplitude de $PPeak$ varia, para cada nível de $PLat$ e $NLat$. As sombras ao redor de cada linha representam os intervalos de confiança das probabilidades de detecção. Desta forma, quanto mais estreita a sombra (menor intervalo de confiança) e maior o valor da linha sólida (maior probabilidade de detecção), mais importante é o parâmetro analisado para realizar a detecção do P300.

A amplitude do maior pico revelou-se um bom parâmetro para auxiliar na detecção do P300, apresentando interação significativa ($p < 0,001$) para $PLat = 3, 4, 5, 6$ ([Figura 5.5](#), superior), o que corresponde ao intervalo de $200ms$ a $500ms$. Tal conclusão se deve ao fato é evidenciado pelo fato de que as curvas correspondentes a estas latências apresentam altos valores de probabilidade de detecção e pequenos intervalos de confiança para $PPeak > 7\mu V$. A interação com $NLat$ ([Figura 5.5](#), inferior) foi significativa apenas no intervalo entre $300ms$ e $400ms$ ($NLat = 4$).

Por sua vez, a amplitude do maior vale, cuja influência é examinada na [Figura 5.6](#), apresentou interação significativa ($p < 0,001$) para $PLat = 3, 4, 5$ ([Figura 5.6](#), superior), uma vez que para valores de $NPeak < -10\mu V$ probabilidades de detecção de até 75% foram atingidas. Entretanto, não houve interação significativa entre $NPeak$ e $NLat$ ([Figura 5.6](#), inferior).

O valor da área entre picos ([Figura 5.7](#)) não apresentou significância estatística de forma isolada, mas houve interação significativa ($p < 0,01$) para $PLat = 3, 4$ ([Figura 5.7](#), superior). Não houve interação significativa com $NLat$ ([Figura 5.7](#), inferior). A influência do valor RMS é examinada na [Figura 5.8](#). Este parâmetro apresentou interação significativa ($p < 0,001$) para $PLat = 3, 4$ ([Figura 5.8](#), superior), mas a interação com $NLat$ ([Figura 5.8](#), inferior) não foi significativa.

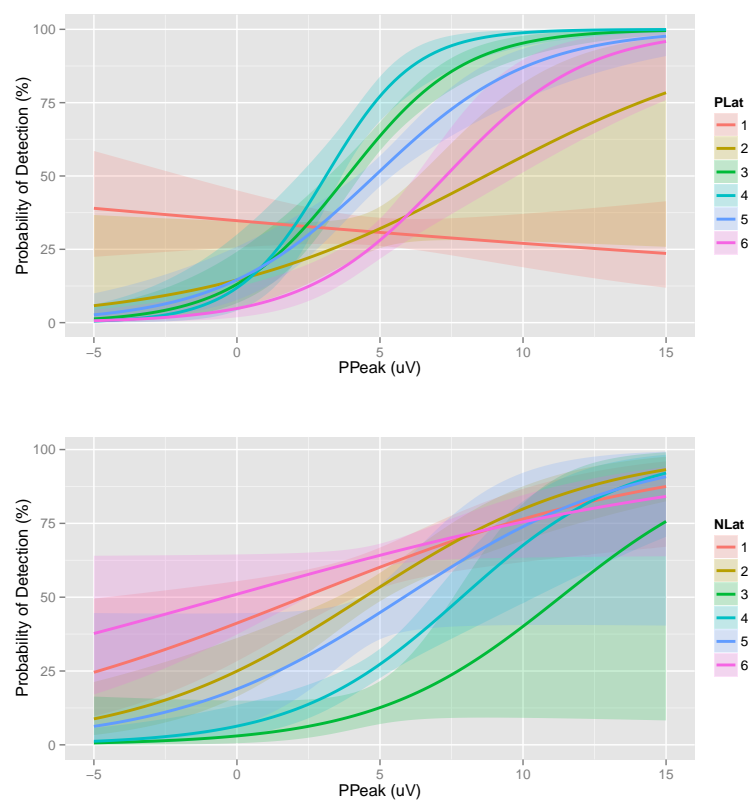


Figura 5.5 – Influência do maior pico na detecção do P300.

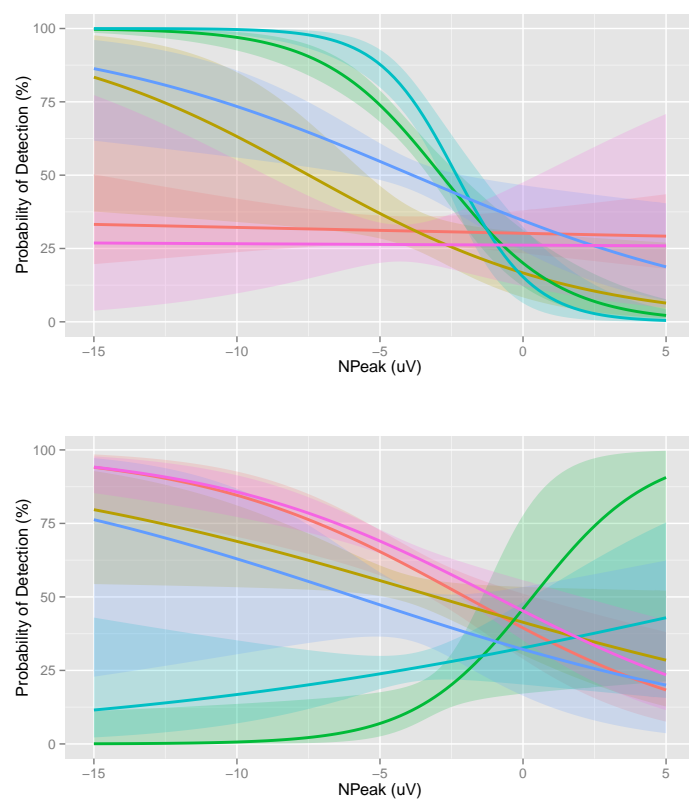


Figura 5.6 – Influência do maior vale na detecção do P300.




Figura 5.7 – Influência do valor da área na detecção do P300.

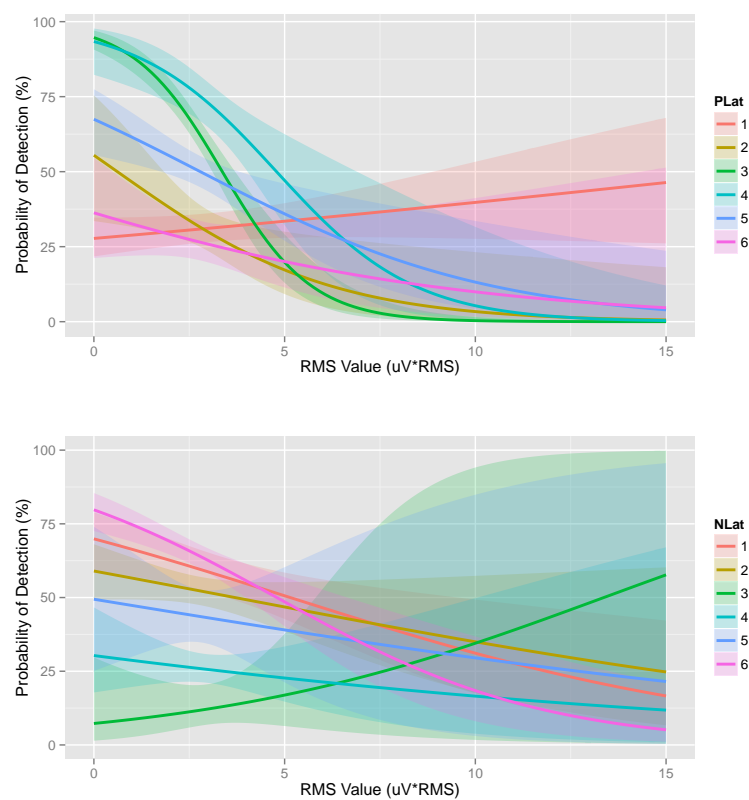


Figura 5.8 – Influência do valor RMS na detecção do P300.

5.2.2 Taxa de Acertos

A [Tabela 5.1](#) apresenta os resultados de detecção dos símbolos obtidos pela ICM baseada em parâmetros P300 de cada voluntário, utilizando-se o número de épocas $N_{ep} = 15$. A terceira coluna contém os símbolos que deveriam ser selecionados (resposta desejada) e os símbolos detectados pela ICM (resposta detectada). Obteve-se uma taxa de acertos média de 61,1%, com desvio padrão de 23,61%.

Tabela 5.1: Resultados de detecção da ICM baseada em parâmetros P300 para $N_{ep} = 15$.

Identificador	Resposta	Símbolos	Taxa
ACS	Detectada	ACVHI OVVB VAFI6 PCCYD	21
	Desejada	SUSHI PERA SALON PERRO	
APM	Detectada	AUSHI CUMIDA COCINA CARPA	91
	Desejada	SUSHI COMIDA COCINA CARPA	
ASG	Detectada	SUSHI CKNAR CILIX VOLCES	71
	Desejada	SUSHI CENAR COLOR DULCESA	
ASR	Detectada	SUSHI SUENO NACHO6 THAT4ISXOK	88
	Desejada	SUSHI SUENO NACHO_ THAT_IS_OK	
CLL	Detectada	5VTNN UAOANEM C6AXWRAKH5 40TA	27
	Desejada	SUSHI NARANJA CUARENTENA ROSA	
DCM	Detectada	SUMHI SOBO_DE_BU C7N3JCZO HICORO	69
	Desejada	SUSHI SOBORDE_TU CONEJITO HIERRO	
DLP	Detectada	5USHI B7BZGIO AF6HXSE 5FTC	39
	Desejada	SUSHI CABALLO ECLIPSE GATO	
DMA	Detectada	NTP11 7FL CJFO RK40L	18
	Desejada	SUSHI BCI CUBO PIXEL	
ELC	Detectada	SUSHI BASFIDI QUOTE PWHNCE	70
	Desejada	SUSHI CASCODO QUOTE PRINCE	
FSZ	Detectada	SUSBB R7MA IMRAI RENOJ	63
	Desejada	SUSHI ROMA CORAL RELOJ	

Identificador	Resposta	Símbolos	Taxa (%)
GCE	Detectada	HUAHI CDGZB AOTCH _3CA	47
	Desejada	SUSHI CASTA BATCH ROCA	
ICE	Detectada	STT22 AUTUBKAVF TETAT HTEYI	46
	Desejada	SUSHI AUTOCLAVE ZETAS HIELO	
IZH	Detectada	V1SNN C_87JVQ1Q YOY BJOMEDGCA	54
	Desejada	SUSHI 1987JUN19 YOU BIOMEDICA	
JLD	Detectada	SUSHI HOLA FEO PAULS	94
	Desejada	SUSHI HOLA FEO PAULA	
JLP	Detectada	XCGHI HAQIFWVO LIBXO DAQIO	48
	Desejada	SUSHI LAPICERO LIBRO BANCO	
JMR	Detectada	SUSGG PERVO ABRCO TCKON1	67
	Desejada	SUSHI PERRO BARCO TIMON1	
JSC	Detectada	G4TLL GMA1 LAXAN FOUOU	26
	Desejada	SUSHI GATO LAPIZ BOTON	
JST	Detectada	SUSHI ZUKY MAANE JY1R	67
	Desejada	SUSHI ZUKY MAYTE AZUL	
LAC	Detectada	SVSHI LAURA DANZA CASA	95
	Desejada	SUSHI LAURA DANZA CASA	
LAG	Detectada	YUSHI DORMIQ QUUERO6COCA HAMARA	79
	Desejada	SUSHI DORMIR QUIERO_COCA HAMBRE	
LGP	Detectada	SVSHI VITAL FUF_ZA PAFAMATRO	80
	Desejada	SUSHI VITAL FUERZA PARAMETRO	
PGA	Detectada	MUYTT HRJMZO FY90 AGUS PADFL	46
	Desejada	SUSHI TRIPTOFANO AGUA PAVEL	
WFG	Detectada	SUSHI U5M8H JNGQNZBRIA AICQEDIUA	62
	Desejada	SUSHI UAM_I INGENIERIA BIOMEDICA	
XCL	Detectada	SUSHI GATO NBZ PERRO	88
	Desejada	SUSHI GATO PEZ PERRO	
Média			61,1%
Desvio padrão			23,61%

A variação da taxa de acertos de símbolos de acordo com o número de épocas pode ser verificada na [Figura 5.9](#) para, $N_{ep} = 1...15$. Observa-se que o aumento do número de épocas promove melhoria na taxa de acertos de símbolos, havendo valores médios e máximos, respectivamente, de 61,1% e 98% para $N_{ep} = 15$.




Figura 5.9 – Taxas de acertos de símbolos da ICM baseada em parâmetros P300.

5.2.3 Taxa de Transferência da Informação

A influência do número de épocas utilizadas na taxa de transferência de informação obtida pela ICM é demonstrada na [Figura 5.10](#). O aumento do número de épocas utilizadas promove melhoria na taxa de transferência de informação da ICM até $N_{ep} = 7$. Após esse valor, a taxa de transferência de informação permanece estável conforme N_{ep} cresce.

A ICM obteve maior taxa de transferência de informação utilizando-se $N_{ep} = 7$, com um valor médio de 2,6 *bits/min* e desvio padrão de 2,48 *bits/min*. Para $N_{ep} = 15$, o valor médio da taxa de transferência de informação e desvio padrão foram, respectivamente, 2,38 *bits/min* e 1,36 *bits/min*.




Figura 5.10 – Taxas de transferência de informação da ICM baseada em parâmetros P300.

5.3 Desempenho da ICM Baseada na Forma de Onda

5.3.1 Taxa de Acertos

A [Tabela 5.2](#) apresenta os resultados de detecção dos símbolos obtidos com a ICM baseada na forma de onda de cada voluntário, utilizando-se o número de épocas $N_{ep} = 15$. Obteve-se uma taxa de acertos de símbolos média de 96%, com desvio padrão de 6,47%.

Tabela 5.2: Resultados de detecção da ICM baseada na forma de onda para $N_{ep} = 15$.

Identificador	Resposta	Símbolos	Taxa
ACS	Detectada	SUSHH PWRB SALON OER_O	79
	Desejada	SUSHI PERA SALON PERRO	
APM	Detectada	SUSHI COMIDA COCINA CARPA	100
	Desejada	SUSHI COMIDA COCINA CARPA	
ASG	Detectada	SUSHI CENAR COLOR DULCES	100
	Desejada	SUSHI CENAR COLOR DULCESA	
ASR	Detectada	SUSHI SUENO NFCI09 TGAT_IS_OK	85
	Desejada	SUSHI SUENO NACHO_ THAT_IS_OK	
CLL	Detectada	SUSHI NARANJA CUARENTENA ROSA	100
	Desejada	SUSHI NARANJA CUARENTENA ROSA	
DCM	Detectada	SUSHI SOBORDE_TU CONEJITO HIERRO	100
	Desejada	SUSHI SOBORDE_TU CONEJITO HIERRO	
DLP	Detectada	SUWHI CABALJO ECLIPSE GATO	96
	Desejada	SUSHI CABALLO ECLIPSE GATO	
DMA	Detectada	SUSHI BCI CUFO PIXAL	88
	Desejada	SUSHI BCI CUBO PIXEL	
ELC	Detectada	SUSHI CASCODO QUOTE PRINCE	100
	Desejada	SUSHI CASCODO QUOTE PRINCE	
FSZ	Detectada	SUSHI ROMA CORAL RELOJ	100
	Desejada	SUSHI ROMA CORAL RELOJ	
GCE	Detectada	HUSHI CAGTA BATCH ROCA	89
	Desejada	SUSHI CASTA BATCH ROCA	
ICE	Detectada	SUS66 AUTOCLAVE ZETAS HIELO	92
	Desejada	SUSHI AUTOCLAVE ZETAS HIELO	

Identificador	Resposta	Símbolos	Taxa (%)
IZH	Detectada	SUSHI 1987JUN19 YOU BIOMEDICA	100
	Desejada	SUSHI 1987JUN19 YOU BIOMEDICA	
JLD	Detectada	SUSHI HOLA FEO PAULA	100
	Desejada	SUSHI HOLA FEO PAULA	
JLP	Detectada	SUSHI LAPIAERO LIBXO BANCO	91
	Desejada	SUSHI LAPICERO LIBRO BANCO	
JMR	Detectada	SUSHI PERRO BARCO TIMON1	100
	Desejada	SUSHI PERRO BARCO TIMON1	
JSC	Detectada	AUSHI GABO LAPIZ BOTIN	84
	Desejada	SUSHI GATO LAPIZ BOTON	
JST	Detectada	SUSHI ZUKY MAYTE AZUL	100
	Desejada	SUSHI ZUKY MAYTE AZUL	
LAC	Detectada	SUSHI LAURA DANZA CASA	100
	Desejada	SUSHI LAURA DANZA CASA	
LAG	Detectada	SUSHI DURSIR QUIERO_COCA HAMBRE	100
	Desejada	SUSHI DORMIR QUIERO_COCA HAMBRE	
LGP	Detectada	SUSHI VITAL FUERZA PARAMETRO	100
	Desejada	SUSHI VITAL FUERZA PARAMETRO	
PGA	Detectada	SUSHI TRIPTOFANO AGUA PAVEL	100
	Desejada	SUSHI TRIPTOFANO AGUA PAVEL	
WFG	Detectada	SUSHI UAM_I INGENIERIA BIOMEDICA	100
	Desejada	SUSHI UAM_I INGENIERIA BIOMEDICA	
XCL	Detectada	SUSHI GATO PEZ PERRO	100
	Desejada	SUSHI GATO PEZ PERRO	
Média			96%
Desvio padrão			6,47%

A variação da taxa de acertos de símbolos de acordo com o número de épocas pode ser verificada na [Figura 5.11](#). Observa-se que o aumento do número de épocas promove melhoria evidente na taxa de acertos de símbolos até $N_{ep} = 10$, a partir do qual os valores médios de acertos são consistentemente acima de 92%.




Figura 5.11 – Taxas de acertos da ICM baseada na forma de onda.

5.3.2 Taxa de Transferência de Informação

A ICM obteve maior taxa de transferência de informação utilizando-se $N_{ep} = 4$, com um valor médio de $10,1 \text{ bits/min}$ e desvio padrão de $4,3 \text{ bits/min}$. Para $N_{ep} = 15$, o valor da taxa média de transferência de informação e desvio padrão foram, respectivamente, $4,8 \text{ bits/min}$ e $0,6 \text{ bits/min}$.

A influência do número de épocas utilizadas na taxa de transferência de informação obtida pela ICM é demonstrada na [Figura 5.12](#). O aumento do número de épocas utilizadas promove melhoria na taxa de transferência de informação da ICM até $N_{ep} = 4$, valor a partir do qual a mesma começa a cair com o crescimento do número de épocas.




Figura 5.12 – Taxas de transferência de informação da ICM baseada na forma de onda.

5.4 Comparação Estatística do Desempenho das ICM

O resultado do Teste de Wilcoxon Pareado indicou haver diferença estatística entre as taxas de acerto e taxas de transferência de informação para todos os valores de número de épocas (N_{ep}), com vantagem para a ICM baseada em forma de onda.

6 Discussão

Este capítulo discute os resultados obtidos, comparando-os com os objetivos iniciais estabelecidos e com trabalhos similares.

6.1 Avaliação das Formas de Onda e Parâmetros dos Potenciais P300

A análise das médias coerentes das épocas de EEG indicou que existe uma grande variabilidade no padrão de formas de onda dos sinais que contém o P300 eliciado, fato este comprovado pelos diferentes formatos observados para este potencial. Duas causas principais poderiam explicar esta variabilidade:

1. A diferença entre as capacidades cognitivas dos diferentes voluntários. Conforme [Polich \(2007\)](#) e [Sur e Sinha \(2009\)](#), duas variáveis interferem diretamente na eliciação do P300: i) a capacidade mental de classificação de estímulos a partir da identificação de contexto interfere diretamente na latência de ocorrência do P300; ii) a capacidade de atenção a diferentes estímulos interfere diretamente na amplitude do potencial eliciado. Deste modo, pode-se inferir que a variação destas duas variáveis seja em parte responsável pelas diferenças apresentadas pelos potenciais;
2. A natureza da percepção ao estímulo de cada usuário. [Polich \(2007\)](#) e [Comerchero e Polich \(1999\)](#) citam que as duas componentes do P300, P3a e P3b, são eliciadas de acordo com a natureza da percepção, que pode ser ativa ou de baixo nível. Portanto, as diferentes naturezas de percepção de cada usuário poderão ser responsáveis por elicitar uma ou outra componente, ocasionando diferenças na forma de onda resultante.

A variabilidade observada levanta a questão de quais são as melhores características para descrever os sinais que contém o P300 eliciado. Neste sentido, alguns pontos podem ser inferidos a partir da análise estatística realizada sobre diferentes parâmetros extraídos dos potenciais ([VIANA; BATISTA; MELGES, 2014](#)):

1. O P300 é caracterizado pelo seu pico positivo proeminente ([POLICH, 2007](#)), o que se reflete na significância encontrada para *PPeak* como característica que efetivamente contribui para identificação de sua ocorrência e corrobora os resultados de outros trabalhos ([FARWELL; DONCHIN, 1988](#); [ALLISON; PINEDA, 2003](#));

2. O fato de *PPeak* apresentar maior dispersão a partir do zero para sinais *target* que para sinais *non-target* pode explicar a significância do *RMS* como característica capaz de prever a eliciação do potencial;
3. Sinais *target* e *non-target* apresentam partes positivas e negativas. Como o cálculo da *Area* realiza a soma de todas estas partes, o resultado final pode levar a valores baixos e muito próximos, incapazes de diferenciar as duas classes;
4. A ausência de significância de *NPeak* reflete a ausência de vales proeminentes característicos deste potencial;
5. A significância das interações entre os parâmetros de amplitude e latência sugere o uso de modelos espaço-temporais para detecção do P300.

Deve ser ressaltado que a grande variabilidade inter-individual nos padrões das formas de onda dificulta fortemente o emprego da ICM, já que se torna necessária a realização de um treinamento individual. Este ponto deve ser analisado cuidadosamente, visando reduzir ao máximo o tempo de treinamento necessário.

Outro fator não analisado neste trabalho, mas que deve ser levado em conta, é o fenômeno da habituação aos estímulos nos padrões de forma de onda, situação em que a amplitude de resposta pode cair, causando queda de desempenho na ICM e até mesmo necessidade de retreinamento.

6.2 Desempenho das ICM Desenvolvidas

A ICM baseada em padrões espaço-temporais das formas de onda de cada derivação apresentou melhores resultados que aquela baseada em parâmetros P300, tanto para taxa de acertos quanto para taxa de transferência de informação.

Uma possível explicação para essa diferença é o fato de que os parâmetros selecionados (*PPeak*, *PLat*, *NPeak*, *NLat*, *Area*, *RMS*) não conseguem modelar bem o P300, limitando, portanto, a possibilidade de detecção.

Considerando a ICM baseada em padrões espaço-temporais das formas de onda, observou-se que a taxa de acertos de símbolos aumenta à medida que o número de épocas utilizadas para o cálculo da média coerente cresce. Uma relação oposta ocorre para a taxa de transferência de informação para valores de $N_{ep} > 5$, que decresce com o aumento do número de épocas.

Estes comportamentos antagônicos estabelecem uma relação de compromisso, gerando as seguintes perguntas:

- Qual o ponto ótimo de operação da ICM em relação ao número de épocas?
- Qual fator privilegiar: a taxa de acertos ou a taxa de transferência de informação?
- O que é melhor para o usuário: acertar grande parte dos símbolos de forma mais lenta ou acertar uma quantidade menor a uma velocidade maior?

Diversos trabalhos apresentam visões diferentes sobre este ponto. [Sellers et al. \(2006\)](#) e [Wolpaw et al. \(2002\)](#) argumentam que, embora a taxa de transferência de informação seja uma medida objetiva do desempenho da ICM, a taxa de acertos é fundamental. Esta posição é justificada na hipótese de que o usuário da ICM pode se sentir frustrado quando percebe que está errando, gerando uma situação de impotência que, em caso de pessoas com deficiências motoras, pode gerar uma reação ao uso de dispositivos de tecnologia assistiva. Baseando-se nesta opinião, parece mais adequado manter o número de sequências elevado, visando atingir taxas de acerto próximas a 100%. Assim, o ponto de operação ótimo para a ICM desenvolvida seria de $N_{ep} = 15$. Contudo, esta abordagem pode levar a uma taxa de transferência de informação tão baixa que o uso da ICM se torna impraticável.

[Farwell e Donchin \(1988\)](#) sugerem uma taxa mínima de 80% para operação da ICM. Adotando este mesmo critério para a ICM desenvolvida, o ponto ótimo de operação seria de $N_{ep} = 6$, onde se obteve uma taxa de acertos de 80% e taxa de transferência de informação de 8,5 *bits/min*.

6.3 Comparação com Resultados da Literatura

A [Tabela 6.1](#) resume os resultados de diversas ICM baseadas em P300 encontradas na literatura e a ICM desenvolvida neste trabalho. Uma análise qualitativa permite concluir que, em relação à taxa de acertos, a ICM desenvolvida apresentou melhores resultados do que a maioria dos trabalhos, mostrando desempenho idêntico ao encontrado por [Shen et al. \(2014\)](#).

A análise comparativa da taxa de transferência de informação é mais difícil de ser realizada, pois muitas ICM reportadas na literatura utilizam um número de épocas variável e não consideram o intervalo entre a seleção dos símbolos.

Desconsiderando-se este intervalo, a ICM desenvolvida neste trabalho atingiu uma taxa de transferência de informação média de 12,8 *bits/min*.

Observa-se, ainda, que os resultados obtidos foram compatíveis com os resultados apresentados na literatura.

Tabela 6.1 – Comparação de diferentes ICM Baseadas em P300.

ICM	Número de Voluntários	Acertos (%)	Informação (bits/min)
Este trabalho	24	96	4.8
Serby, Yom-Tov e Inbar (2005)	6	79,5	13,3*
Sellers <i>et al.</i> (2006)	5	85	3,34
Lenhardt, Kaper e Ritter (2008)	12	83,3	19,55*
Nijboer <i>et al.</i> (2008)	4	78,8	9,8
Guger <i>et al.</i> (2009)	81	91	-
Townsend <i>et al.</i> (2010)	18	77,3	19,85*
Pires, Nunes e Castelo-Branco (2011)	23	90,3	18,15*
Pires, Nunes e Castelo-Branco (2012)	10	89,3	18,94*
Combaz <i>et al.</i> (2012)	9	80	-
Eom <i>et al.</i> (2013)	5	62	-
Chen <i>et al.</i> (2014)	10	94	-
Shen <i>et al.</i> (2014)	7	96	23,01*

Nota: * Utilizam número variável de épocas. O intervalo entre seleção de símbolos não é contabilizado.

6.4 Análise dos Objetivos do Projeto Final de Curso

Todos os objetivos propostos neste trabalho foram atingidos. A obtenção das formas de onda para os diferentes usuários permitiu avaliar as diferenças dos potenciais P300 inter-usuário, cujas características mais representativas foram selecionadas. A investigação das técnicas de processamento de sinais permitiu escolher um conjunto de métodos que, empregados na construção da ICM proposta e validados com sinais reais, apresentaram elevadas taxas de acerto, que viabilizarão seu uso *online*.

Fora do escopo dos objetivos iniciais, destaca-se o desenvolvimento de um esti-

mulador para eliciação de P300, que poderá ser utilizado em futuros experimentos no NEPEB, contribuindo para o estudo e criação de dispositivos de tecnologia assistiva que poderão beneficiar as pessoas que sofram de ELA ou outras desordens neuromotoras.

Além disso, parte deste projeto foi dedicada ao desenvolvimento de um novo método de seleção de características, cujos resultados foram recentemente publicados em [Viana, Batista e Melges \(2014\)](#).

7 Conclusão

Este capítulo apresenta as conclusões finais do projeto, bem como sugestões de trabalhos futuros.

Neste trabalho, foram estudadas as diferenças na eliciação do P300 para diversos usuários, bem como técnicas de processamento de sinais que podem ser empregadas na sua detecção. Foi proposto um novo método para identificar quais características de EEG são significativas para detecção do P300.

Duas ICM distintas foram desenvolvidas: a primeira, baseada em parâmetros P300; a segunda, baseada em padrões espaço-temporais presentes nas formas de onda das diversas derivações do EEG. Ambas as ICM provaram-se capazes de detectar o P300, sendo a ICM baseada nas formas de onda aquela que apresentou melhor desempenho.

As taxas de acertos de símbolos obtidas são equiparáveis aos resultados mais recentes da literatura, alcançando um valor médio de 96% de símbolos detectados corretamente. As taxas de transferência de informação também foram adequadas, com valor médio de 4,8 *bits/min*.

Visando melhorar o desempenho da ICM, sugere-se os seguintes trabalhos:

- Implementar algoritmo automático de seleção de características, baseado em testes de coeficientes de modelos de regressão logística;
- Implementar número variável de épocas, a partir da determinação de um limiar de probabilidade de detecção do potencial, possibilitando aumentar a taxa de transferência de informação;
- Avaliar quais são as melhores derivações para detecção, buscando diminuir o número de eletrodos utilizados;

Por fim, como os resultados alcançados pela ICM desenvolvida são bastante promissores, pretende-se aplicá-los nos seguintes trabalhos futuros:

- Utilizar estimulador desenvolvido em paralelo com este projeto para coleta de sinais de EEG que contenham o P300 eliciado, possibilitando realizar a implementação *online* da ICM;

- Testar o algoritmo de detecção de P300 desenvolvido em outros tipos de ICM, tais como controle de cadeira de rodas motorizada, controle de ambientes domóticos e *softwares* de acessibilidade para dispositivos eletrônicos.

Referências

AGUIRRE, L. *Introdução à Identificação de Sistemas – Técnicas Lineares e Não-Lineares Aplicadas a Sistemas Reais*. Editora UFMG, 2007. ISBN 9788570415844. Disponível em: <http://books.google.com.br/books?id=f9IwE7Ph0fYC>. Citado na página 19.

ALHADDAD, M. J. Common Average Reference (CAR) Improves P300 Speller. *International Journal of Engineering and Technology*, v. 2, n. 3, p. 451–465, 2012. Disponível em: http://iet-journals.org/archive/2012/march_vol_2_no_3-/381359132985477.pdf. Citado na página 18.

ALHADDAD, M. J.; KAMEL, M.; MALIBARY, H.; THABIT, K.; DAHLWI, F.; HADI, A. P300 speller efficiency with common average reference. In: *Proceedings of the Third international conference on Autonomous and Intelligent Systems*. [s.n.], 2012. p. 234–241. Disponível em: http://link.springer.com/chapter/10.1007/978-3-642-31368-4_28. Citado 3 vezes nas páginas 17, 18 e 30.

ALLISON, B. Z.; PINEDA, J. A. ERPs evoked by different matrix sizes: implications for a brain-computer interface (BCI) system. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, v. 11, n. 2, p. 110–113, 2003. Disponível em: <http://dx.doi.org/10.1109/tnsre.2003.814448>. Citado 5 vezes nas páginas 3, 19, 22, 30 e 56.

ALOISE, F.; SCHETTINI, F.; ARICÒ, P.; SALINARI, S.; GUGER, C.; RINSMA, J.; AIELLO, M.; MATTIA, D.; CINCOTTI, F. Asynchronous p300-based brain-computer interface to control a virtual environment: initial tests on end users. *Clinical EEG and Neuroscience*, v. 42, n. 4, p. 219–224, 2011. Disponível em: <http://eeg.sagepub.com/content/42/4/219.short>. Citado na página 25.

ANDERSON, C. W.; DEVULAPALLI, S. V.; STOLZ, E. A. Eeg signal classification with different signal representations. In: *Neural Networks for Signal Processing, IEEE Service Center, Piscataway, NJ*. [s.n.], 1995. p. 475–483. Disponível em: <http://dx.doi.org/10.1109/NNSP.1995.514922>. Citado na página 21.

BASHASHATI, A.; FATOURECHI, M.; WARD, R. K.; BIRCH, G. E. A survey of signal processing algorithms in brain-computer interfaces based on electrical brain signals. *Journal of Neural Engineering*, v. 4, n. 2, p. R32, 2007. Disponível em: <http://stacks.iop.org/1741-2552/4/i=2/a=R03>. Citado 4 vezes nas páginas 3, 16, 17 e 20.

BASHASHATI, A.; WARD, R.; BIRCH, G. A new design of the asynchronous brain computer interface using the knowledge of the path of features. In: *2nd International IEEE EMBS Conference on Neural Engineering*. [s.n.], 2005. p. 101 –104. Disponível em: <http://dx.doi.org/10.1109/CNE.2005.1419563>. Citado na página 21.

BAYLISS, J. D. Use of the evoked potential p3 component for control in a virtual apartment. *Neural Systems and Rehabilitation Engineering, IEEE Transactions on*, v. 11, n. 2, p. 113–116, 2003. Disponível em: <http://dx.doi.org/10.1109/TNSRE.2003.814438>. Citado na página 25.

- BAYLISS, J. D.; BALLARD, D. H. Single trial p300 recognition in a virtual environment. In: *University of Rochester*. [s.n.], 1999. p. 22–25. Disponível em: <http://vrlab.cps.utexas.edu/papers/scb99.pdf>. Citado 2 vezes nas páginas 19 e 25.
- BELL, A. J.; SEJNOWSKI, T. J. An information-maximization approach to blind separation and blind deconvolution. *Neural Computation*, v. 7, n. 6, p. 1129–1159, 1995. Disponível em: <http://dx.doi.org/10.1162/neco.1995.7.6.1129>. Citado na página 20.
- BLACKWOOD, W. J. M. D. H. Cognitive brain potentials and their application. *The British Journal of Psychiatry*, v. 157, n. 1, p. 96 – 101, 1990. Disponível em: <http://www.ncbi.nlm.nih.gov/pubmed/2291824>. Citado na página 8.
- BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. In: *Proceedings of the Fifth Annual Workshop on Computational Learning Theory*. ACM, 1992. p. 144–152. Disponível em: <http://doi.acm.org/10.1145/130385-130401>. Citado na página 34.
- BOUGRAIN C. SAAVEDRA, R. R. L. Finally, what is the best filter for p300 detection? In: *Proceedings of the TOBI Workshop III - Tools for Brain-Computer Interaction*. [s.n.], 2012. Disponível em: <http://hal.archives-ouvertes.fr/docs/00/75-/66/69/PDF/Bougrain-TobiWorkshop12Final.pdf>. Citado 2 vezes nas páginas 17 e 18.
- BROUWER, A.-M.; ERP, J. B. F. van. An auditory oddball (P300) spelling system for brain-computer interfaces. *Frontiers in Neuroscience*, v. 4, 2010. Disponível em: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC2871714/>. Citado na página 23.
- BURGES, C. J. A tutorial on support vector machines for pattern recognition. *Data Mining and Knowledge Discovery*, v. 2, p. 121–167, 1998. Disponível em: <http://dl.acm.org/citation.cfm?id=593463>. Citado 2 vezes nas páginas 35 e 36.
- CARDOSO, J.-F.; SOULOUMIAC, A. Blind beamforming for non gaussian signals. *IEEE Proceedings-F on Radar and Signal Processing*, v. 140, p. 362–370, 1993. Disponível em: <http://digital-library.theiet.org/content/journals/10.1049/ip-f-2.1993.0054>. Citado na página 20.
- CHEN, L.; JIN, J.; ZHANG, Y.; WANG, X.; CICHOCKI, A. A survey of the dummy face and human face stimuli used in bci paradigm. *Journal of Neuroscience Methods*, 2014. Disponível em: <http://dx.doi.org/10.1016/j.jneumeth.2014.10.002>. Citado na página 59.
- CITI, L.; POLI, R.; CINEL, C.; SEPULVEDA, F. P300-based bci mouse with genetically-optimized analogue control. *Neural Systems and Rehabilitation Engineering, IEEE Transactions on*, v. 16, n. 1, p. 51–61, 2008. Disponível em: <http://dx.doi.org/10.1109/TNSRE.2007.913184>. Citado na página 21.
- COMBAZ, A.; CHUMERIN, N.; MANYAKOV, N.; ROBBEN, A.; SUYKENS, J.; HULLE, M. V. Towards the detection of error-related potentials and its integration in the context of a {P300} speller brain-computer interface. *Neurocomputing*, v. 80, n. 0, p. 73 – 82, 2012. Disponível em: <http://dx.doi.org/10.1016/j.neucom.2011.09.013>. Citado na página 59.

- COMERCHERO, M. D.; POLICH, J. P3a and p3b from typical auditory and visual stimuli. *Clinical Neurophysiology*, v. 110, p. 24–30, 1999. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/10348317>>. Citado 2 vezes nas páginas 12 e 56.
- COMON, P. Independent component analysis, a new concept? *Signal Processing*, v. 36, n. 3, p. 287–314, 1994. Disponível em: <[http://dx.doi.org/10.1016/0165-1684\(94\)90029-9](http://dx.doi.org/10.1016/0165-1684(94)90029-9)>. Citado na página 20.
- CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, v. 20, n. 3, p. 273–297, 1995. Disponível em: <<http://dx.doi.org/10.1023/A:1022627411411>>. Citado 2 vezes nas páginas 34 e 36.
- DIETRICH, A.; KANSO, R. A review of eeg, erp, and neuroimaging studies of creativity and insight. *Psychology Bulletin*, v. 136, n. 5, p. 822–848, 2010. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/20804237>>. Citado na página 5.
- DUDA, R. O.; HART, P. E.; STORK, D. G. *Pattern classification*. [S.l.]: John Wiley & Sons, 2012. Citado na página 22.
- EFRON, B.; HASTIE, T.; JOHNSTONE, I.; TIBSHIRANI, R. Least angle regression. *The Annals of statistics*, v. 32, n. 2, p. 407–499, 2004. Disponível em: <<http://dx.doi.org/10.1214/009053604000000067>>. Citado na página 33.
- ELSHOUT, J.; MOLINA, G. G. *Review of brain-computer interfaces based on the P300 evoked potential*. Philips Research Europe, 2009. Disponível em: <dspace.library.uu.nl/handle/1874/33417>. Citado na página 14.
- EOM, J.-S.; YANG, H.-R.; PARK, M.-S.; SOHN, J.-H. P300 speller using a new stimulus presentation paradigm. In: *Brain-Computer Interface (BCI), 2013 International Winter Workshop on*. [S.l.: s.n.], 2013. p. 98–99. Citado na página 59.
- FABIANI, M.; GRATTON, G.; KARIS, D.; DONCHIN, E. Definition, identification, and reliability of measurement of the p300 component of the event-related brain potential. *Advances in Psychophysiology*, v. 2, p. 1, 1987. Disponível em: <http://scholarcommons.usf.edu/psy_facpub/286/>. Citado na página 14.
- FARWELL, L. A.; DONCHIN, E. Talking off the top of your head: Toward a mental prosthesis utilizing event-related brain potentials. *Electroencephalography and Clinical Neurophysiology*, v. 70, p. 510–523, 1988. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/2461285>>. Citado 8 vezes nas páginas 17, 19, 22, 24, 29, 30, 56 e 58.
- FERREZ, P. W.; MILLAN, J. del R. Error-related eeg potentials generated during simulated brain-computer interaction. *IEEE Transactions on Biomedical Engineering*, v. 55, n. 3, p. 923–929, 2008. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/18334383>>. Citado na página 23.
- FINKE, A.; LENHARDT, A.; RITTER, H. The mindgame: a p300-based brain-computer interface game. *Neural Networks*, v. 22, n. 9, p. 1329–1333, 2009. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0893608009001579>>. Citado na página 25.

- FURDEA, A.; HALDER, S.; KRUSIENSKI, D. J.; BROSS, D.; NIJBOER, F.; BIRBAUMER, N.; KÜBLER, A. An auditory oddball (P300) spelling system for brain-computer interfaces. *Psychophysiology*, v. 46, n. 3, p. 617–625, 2009. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/19170946>>. Citado na página 23.
- GUGER, C.; DABAN, S.; SELLERS, E.; HOLZNER, C.; KRAUSZ, G.; CARABALONA, R.; GRAMATICA, F.; EDLINGER, G. How many people are able to control a p300-based brain-computer interface (bci)? *Neuroscience letters*, v. 462, n. 1, p. 94–98, 2009. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0304394009008192>>. Citado 2 vezes nas páginas 24 e 59.
- GUGER, C.; EDLINGER, G.; HARKAM, W.; NIEDERMAYER, I.; PFURTSCHELLER, G. How many people are able to operate an EEG-based brain-computer interface (BCI)? *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, v. 11, n. 2, p. 145–147, 2003. Disponível em: <dx.doi.org/10.1109/TNSRE.2003.814481>. Citado na página 24.
- HUGHES, J. R. Gamma, fast, and ultrafast waves of the brain: Their relationships with epilepsy and behavior. *Epilepsy and Behavior*, v. 13, n. 1, p. 25 – 31, 2008. Disponível em: <<http://dx.doi.org/10.1016/j.yebeh.2008.01.011>>. Citado na página 6.
- HYVARINEN, A.; OJA, E. Independent component analysis: Algorithms and applications. *Neural Networks*, v. 13, n. 3, p. 411–430, 2000. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/10946390>>. Citado na página 20.
- ITURRATE, I.; ANTELIS, J. M.; KUBLER, A.; MINGUEZ, J. A noninvasive brain-actuated wheelchair based on a p300 neurophysiological protocol and automated navigation. *IEEE Transactions on Robotics*, IEEE, v. 25, n. 3, p. 614–627, 2009. Citado na página 25.
- JANSEN, B. H.; ALLAM, A.; KOTA, P.; LACHANCE, K.; OSHO, A.; SUNDARESAN, K. An exploratory study of factors affecting single trial P300 detection. *IEEE Transactions Biomedical Engineering*, v. 51, n. 6, p. 975–978, 2004. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/15188867>>. Citado na página 22.
- JASPER, H. H. Report of the committee on methods of clinical examination in electroencephalography. *Electroencephalography and Clinical Neurophysiology*, v. 10, n. 2, p. 370 – 375, 1958. Disponível em: <[http://dx.doi.org/10.1016/0013-4694\(58\)90053-1](http://dx.doi.org/10.1016/0013-4694(58)90053-1)>. Citado na página 7.
- KAPER, M.; MEINICKE, P.; GROSSEKATHÖFER, U.; LINGNER, T.; RITTER, H. Bci competition 2003-data set iib: support vector machines for the p300 speller paradigm. *IEEE Transactions on Biomedical Engineering*, v. 51, n. 6, p. 1073–1076, 2004. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/15188881>>. Citado na página 36.
- KILGORE, K.; PECKHAM, P.; KEITH, M.; THROPE, G.; WUOLLE, K.; BRYDEN, A.; HART, R. An implanted upper-extremity neuroprosthesis. follow-up of five patients. *Journal of Bone and Joint Surgery*, v. 79, n. 4, p. 533–541, 1997. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/9111397>>. Citado 2 vezes nas páginas 2 e 3.

- KLASS, D. W. The continuing challenge of artifacts in the eeg. *American Journal of EEG Technology*, v. 35, n. 1, p. 239 – 269, 1995. Disponível em: <http://www.msetinfo.org/pdf/The_Continuous_Challenge_of_Artifacts_in_the_EEG_1.pdf>. Citado na página 8.
- KRAMER, M. A. Nonlinear principal component analysis using autoassociative neural networks. *AIChE Journal*, v. 37, n. 2, p. 233–243, 1991. Disponível em: <<http://dx.doi.org/10.1002/aic.690370209>>. Citado na página 21.
- KRUSIENSKI, D. J.; SELLERS, E. W.; MCFARLAND, D. J.; VAUGHAN, T. M.; WOLPAW, J. R. Toward Enhanced P300 Speller Performance. *Journal of Neuroscience Methods*, v. 167, n. 1, p. 15–21, 2008. Disponível em: <<http://dx.doi.org/10.1016/j.jneumeth.2007.07.017>>. Citado 2 vezes nas páginas 18 e 22.
- KÜBLER, A.; HALDER, S.; FURDEA, A.; HÖSLE, A. Brain painting-bci meets art. In: *Proceedings of the 4th International Brain-Computer Interface Workshop and Training Course*. [S.l.: s.n.], 2008. p. 361–366. Citado na página 25.
- KüBLER, A.; KOTCHOUBEY, B.; HINTERBERGER, T.; GHANAYIM, N.; PERELMOUTER, J.; SCHAUER, M.; FRITSCH, C.; TAUB, E.; BIRBAUMER, N. The Thought Translation Device: A Neurophysiological Approach to Communication in Total Motor Paralysis. *Experimental Brain Research*, v. 124, n. 2, p. 223–232, 1999. Disponível em: <<http://www.metapress.com/content/FGUE9H81NLPF2JBB>>. Citado na página 23.
- LACOURSE, J.; JR., F. H. An eye movement communication-control system for the disabled. *IEEE Transactions on Biomedical Engineering*, v. 37, n. 12, p. 1215–1220, 2002. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/2149712>>. Citado na página 2.
- LEDESMA-RAMIREZ, C.; BOJORGES-VALDEZ, E.; YÁÑEZ-SUAREZ, O.; SAAVEDRA, C.; BOUGRAIN, L.; GENTILETTI, G. G. *et al.* An open-access p300 speller database. In: *Fourth International Brain-Computer Interface Meeting*. [s.n.], 2010. Disponível em: <<http://hal.inria.fr/inria-00549242/en>>. Citado 2 vezes nas páginas 27 e 28.
- LENHARDT, A.; KAPER, M.; RITTER, H. J. An adaptive p300-based online brain-computer interface. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, v. 16, n. 2, p. 121–130, 2008. Disponível em: <<http://dx.doi.org/10.1109/TNSRE.2007.912816>>. Citado na página 59.
- LI, K. *Advanced Signal Processing Techniques for Single Trial Electroencephalography Signal Classification for Brain Computer Interface Applications*. Tese (Doutorado) — University of South Florida, 2010. Disponível em: <<http://scholarcommons.usf.edu/etd-/3484>>. Citado 2 vezes nas páginas 18 e 20.
- LUCK, S. J. *An introduction to the event-related potential technique*. [S.l.]: MIT Press, 2005. Citado na página 9.
- MASON, S. G.; BIRCH, G. E. A general framework for brain-computer interface design. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, v. 11, n. 1, p. 70–85, 2003. Disponível em: <<http://doi.ieeecomputersociety.org/10.1109/DASC.2009.72>>. Citado 3 vezes nas páginas 3, 15 e 17.

- MCFARLAND, D. J.; MINER, L. A.; VAUGHAN, T. M.; WOLPAW, J. R. Mu and beta rhythm topographies during motor imagery and actual movements. *Brain topography*, v. 12, n. 3, 2000. Disponível em: <[http://link.springer.com/article/10.1023-A:1023437823106](http://link.springer.com/article/10.1023/A:1023437823106)>. Citado na página 16.
- MCFARLAND, D. J.; SARNACKI, W. A.; TOWNSEND, G.; VAUGHAN, T.; A, J. R. W. The P300-based brain-computer interface (BCI): Effects of stimulus rate. *Clinical Neurophysiology*, v. 122, n. 4, p. 731–737, 2011. Disponível em: <<http://dx.doi.org/10.1016/j.clinph.2010.10.029>>. Citado na página 3.
- MELGES, D. B. *Aplicação de Técnicas de Detecção Objetiva nos domínios do tempo e frequência ao EEG durante estimulação somato-sensitiva*. Tese (Doutorado) — Universidade Federal do Rio de Janeiro, 2009. Disponível em: <http://objdig.ufrj.br/60/teses/coppe_d/DaniloBarbosaMelges.pdf>. Citado 2 vezes nas páginas 7 e 11.
- MELGES, D. B.; Sá, A. M. F. L. M. de; INFANTOSI, A. F. C. Frequency-domain objective response detection techniques applied to evoked potentials: A review. In: NAIK, G. R. (Ed.). *Applied Biological Engineering - Principles and Practice*. InTech, 2012. Disponível em: <<http://www.intechopen.com/books/applied-biological-engineering-principles-and-practice/frequency-domain-objective-response-detection-techniques-applied-to-evoked-potentials-a-review>>. Citado na página 7.
- MOORE, M. M. Real-world applications for brain-computer interface technology. *Neural Systems and Rehabilitation Engineering, IEEE Transactions on*, v. 11, n. 2, p. 162–165, 2003. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/12899263>>. Citado na página 15.
- MUGLER, E. M.; RUF, C. A.; HALDER, S.; BENSCH, M.; KUBLER, A. Design and implementation of a p300-based brain-computer interface for controlling an internet browser. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, v. 18, n. 6, p. 599–609, 2010. Disponível em: <<http://dx.doi.org/10.1109/TNSRE.2010.2068059>>. Citado na página 25.
- MÜNSSINGER, J. I.; HALDER, S.; KLEIH, S. C.; FURDEA, A.; RACO, V.; HÖSLE, A.; KÜBLER, A. Brain painting: first evaluation of a new brain-computer interface application with als-patients and healthy volunteers. *Frontiers in Neuroscience*, v. 4, 2010. Disponível em: <<http://www.ncbi.nlm.nih.gov/pmc/articles/PMC2996245/>>. Citado na página 25.
- MYERS, R. H.; MONTGOMERY, D. C.; VINING, G. G.; ROBINSON, T. J. *Generalized linear models: with applications in engineering and the sciences*. [S.l.]: John Wiley & Sons, 2012. Citado 2 vezes nas páginas 31 e 32.
- NICOLAS-ALONSO, L. F.; GOMEZ-GIL, J. Brain computer interfaces, a review. *Sensors*, v. 12, n. 2, p. 1211–1279, 2012. Disponível em: <<http://www.mdpi.com/1424-8220/12/2/1211/pdf>>. Citado 2 vezes nas páginas 14 e 15.
- NIEDERMEYER, E.; SILVA, F. L. da. *Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*. 5th. ed. [S.l.]: Lippincott Williams and Wilkins, 2004. ISBN 0781751268. Citado 6 vezes nas páginas 5, 7, 9, 11, 16 e 27.

- NIJBOER, F.; SELLERS, E.; MELLINGER, J.; JORDAN, M.; MATUZ, T.; FURDEA, A.; HALDER, S.; MOCHTY, U.; KRUSIENSKI, D.; VAUGHAN, T. *et al.* A p300-based brain-computer interface for people with amyotrophic lateral sclerosis. *Clinical Neurophysiology*, v. 119, n. 8, p. 1909–1916, 2008. Disponível em: <<http://dx.doi.org/10.1016/j.clinph.2008.03.034>>. Citado na página 59.
- NOLAN, H.; WHELAN, R.; REILLY, R. B. Faster: Fully automated statistical thresholding for eeg artifact rejection. *Journal of Neuroscience Methods*, v. 192, n. 1, p. 152 – 162, 2010. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/20654646>>. Citado na página 8.
- OLIVEIRA, A. S. B.; PEREIRA, R. D. B. Amyotrophic lateral sclerosis (ALS): three letters that change the people's life. For ever. *Arquivos de Neuro-Psiquiatria*, v. 67, p. 750 – 782, 2009. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/19722069>>. Citado na página 1.
- PETERSON C. E. SCHROEDER, J. C. A. N. N. Neural generators of early cortical somatosensory evoked potentials in the awake monkey. *Electroencephalography and Clinical Neurophysiology*, v. 96, n. 3, p. 248 – 260, 1995. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/7750450>>. Citado na página 8.
- PIERCE, J. R. *An introduction to information theory. Symbols, signals and noise.* 2., rev. ed. ed. Dover Publishing, 1980. Disponível em: <<http://www.loc.gov/catdir/toc-/dover031/80066678.html>>. Citado na página 41.
- PIRES, G.; NUNES, U.; CASTELO-BRANCO, M. Statistical spatial filtering for a p300-based bci: Tests in able-bodied, and patients with cerebral palsy and amyotrophic lateral sclerosis. *Journal of Neuroscience Methods*, v. 195, n. 2, p. 270 – 281, 2011. Disponível em: <<http://dx.doi.org/10.1016/j.jneumeth.2010.11.016>>. Citado 2 vezes nas páginas 29 e 59.
- PIRES, G.; NUNES, U.; CASTELO-BRANCO, M. Comparison of a row-column speller vs. a novel lateral single-character speller: Assessment of {BCI} for severe motor disabled patients. *Clinical Neurophysiology*, v. 123, n. 6, p. 1168 – 1181, 2012. Disponível em: <<http://dx.doi.org/10.1016/j.clinph.2011.10.040>>. Citado na página 59.
- POLICH, J. On the relationship between EEG and P300: individual differences, aging, and ultradian rhythms. *International journal of psychophysiology*, v. 26, n. 1-3, p. 299–317, 1997. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0167876097007721>>. Citado na página 12.
- POLICH, J. Updating p300: An integrative theory of p3a and p3b. *Clinical Neurophysiology*, v. 118, n. 10, p. 2128 – 2148, 2007. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/17573239>>. Citado 2 vezes nas páginas 12 e 56.
- REBSAMEN, B.; TEO, C. L.; ZENG, Q.; ANG, V.; BURDET, E.; GUAN, C.; ZHANG, H.; LAUGIER, C. Controlling a wheelchair indoors using thought. *IEEE Intelligent Systems*, v. 22, n. 2, p. 18–24, 2007. Disponível em: <<http://dx.doi.org/10.1109/MIS-2007.26>>. Citado na página 25.
- ROSENFELD, J. P300 in detecting concealed information. In: VERSCHUERE, B.; BEN-SHAKHAR, G.; MEIJER, E. (Ed.). *Memory Detection: Theory and Application of*

the Concealed Information Test. [S.l.]: Cambridge University Press, 2011. Citado na página 12.

SAUNDERS, M. G. Artifacts: activity of noncerebral origin in the eeg. In: KCLASS, D. W.; DALY, D. D. (Ed.). *Current Practice of Clinical Electroencephalography*. [S.l.]: Raven Press, 1979. Citado na página 8.

SCHÖLKOPF, B.; SMOLA, A. J.; WILLIAMSON, R. C.; BARTLETT, P. L. New support vector algorithms. *Neural computation*, MIT Press, v. 12, n. 5, p. 1207–1245, 2000. Citado 2 vezes nas páginas 37 e 38.

SELLERS, E.; KRUSIENSKI, D.; MCFARLAND, D.; VAUGHAN, T.; WOLPAW, J. A P300 event-related potential brain-computer interface (BCI): the effects of matrix size and inter stimulus interval on performance. *Biological Psychology*, v. 73, n. 3, p. 242–252, 2006. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0301051106001396>>. Citado 3 vezes nas páginas 2, 58 e 59.

SERBY, H.; YOM-TOV, E.; INBAR, G. F. An improved p300-based brain-computer interface. *Neural Systems and Rehabilitation Engineering, IEEE Transactions on*, v. 13, n. 1, p. 89–98, 2005. Disponível em: <<http://dx.doi.org/10.1109/TNSRE.2004.841878>>. Citado 2 vezes nas páginas 40 e 59.

SHEN, J.; LIANG, J.; SHI, J.; WANG, Y. A dynamic submatrix-based p300 online brain-computer interface. *Biomedical Signal Processing and Control*, v. 15, p. 27–32, 2014. Disponível em: <<http://dx.doi.org/10.1016/j.bspc.2014.09.005>>. Citado 2 vezes nas páginas 58 e 59.

SUR, S.; SINHA, V. K. Event-related potential: An overview. *Industrial Psychiatry Journal*, v. 18, n. 1, p. 70 – 73, 2009. Disponível em: <<http://www.ncbi.nlm.nih.gov/pmc/articles/PMC3016705>>. Citado 4 vezes nas páginas 8, 9, 12 e 56.

SUTTON, S.; BRAREN, M.; ZUBIN, J.; JOHN, E. R. Evoked-potential correlates of stimulus uncertainty. *Science*, v. 150, p. 1187–1188, 1965. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/5852977>>. Citado na página 12.

TEPLAN, M. Fundamentals of EEG measurement. *Measurement Science Review*, v. 2, n. 2, p. 1–11, 2002. Disponível em: <<http://www.measurement.sk/2002/S2/Teplan.pdf>>. Citado 2 vezes nas páginas 5 e 6.

TOWNSEND, G.; LAPALLO, B.; BOULAY, C.; KRUSIENSKI, D.; FRYE, G.; HAUSER, C.; SCHWARTZ, N.; VAUGHAN, T.; WOLPAW, J.; SELLERS, E. A novel p300-based brain-computer interface stimulus presentation paradigm: moving beyond rows and columns. *Clinical Neurophysiology*, v. 121, n. 7, p. 1109–1120, 2010. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S1388245710000738>>. Citado na página 59.

VIANA, S. S.; BATISTA, D. de M.; MELGES, D. B. Logistic regression models: Feature selection for p300 detection improvement. In: *XXIV Congresso Brasileiro de Engenharia Biomédica*. [s.n.], 2014. Disponível em: <<http://cbeb.org.br/CBEB2014>>. Citado 3 vezes nas páginas 32, 56 e 60.

VIGÁRIO, R.; JOUSMÄKI, V.; HÄMÄLÄINEN, M.; HARI, R.; OJA, E. Independent component analysis for identification of artifacts in magnetoencephalographic recordings. In: *Proceedings of the Neural Information Processing Systems*. The MIT Press, 1997. Disponível em: <<http://dl.acm.org/citation.cfm?id=302596>>. Citado na página 20.

W, S. E.; DONCHIN, E. A P300-based brain-computer interface: initial tests by ALS patients/interfaces. *Clinical Neurophysiology*, v. 117, n. 3, p. 538–548, 2006. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/16461003/>>. Citado 2 vezes nas páginas 23 e 24.

WOLPAW, J.; BIRBAUMER, N.; MCFARLAND, D.; PFURTSCHELLER, G.; VAUGHAN, T. Brain-computer interfaces for communication and control. *Clinical Neurophysiology*, v. 113, n. 6, p. 167–791, 2002. Disponível em: <[http://doi.acm.org/10-1145/1941487.1941506](http://doi.acm.org/10.1145/1941487.1941506)>. Citado 5 vezes nas páginas 2, 14, 15, 17 e 58.

XU, N.; GAO, X.; HONG, B.; MIAO, X.; GAO, S.; YANG, F. BCI Competition 2003–Data set Iib: enhancing P300 wave detection using ICA-based subspace projections for BCI applications. *IEEE Transactions on Biomedical Engineering*, v. 51, n. 6, p. 1067–1072, 2004. Disponível em: <<http://dx.doi.org/10.1109/tbme.2004.826699>>. Citado na página 19.

ZICKLER, C.; RICCIO, A.; LEOTTA, F.; HILLIAN-TRESS, S.; HALDER, S.; HOLZ, E.; STAIGER-SÄLZER, P.; HOOGERWERF, E.-J.; DESIDERI, L.; MATTIA, D. *et al.* A brain-computer interface as input channel for a standard assistive technology software. *Clinical EEG and Neuroscience*, v. 42, n. 4, p. 236–244, 2011. Disponível em: <<http://eeg.sagepub.com/content/42/4/236.short>>. Citado na página 26.